


**UNIVERSIDAD TECNOLÓGICA NACIONAL**
**FACULTAD REGIONAL CÓRDOBA**
Cátedra de Inteligencia Artificial — Curso 5k2 — Primavera 2026

# TRABAJO PRÁCTICO INTEGRADOR: COMPRENSIÓN VISUAL DE ESCENAS

Informe Técnico y Memoria de Ingeniería del Pipeline Neuro-Simbólico de Percepción, Segmentación, Representación en Grafo de Escena y Razonamiento Factual

**Cuerpo Docente**

- García, Mario Alejandro
- Forte, Guillermo Omar
- Gramática, Martín Nicolás

**Grupo N° 21 — Alumnos**

- Ocampo, Gabriel — Legajo: 93368
- Pecchio, Valentina — Legajo: 94416
- Lopez Quinteros, Manuel — Legajo: 99026
- Chaile, Emmanuel Ricardo — Legajo: 89767
- Perez, Alvaro — Legajo: 97986

**Fecha de Entrega:** 1 de Noviembre de 2026
**Notebook Oficial de Referencia:** `tpi-ia-2026p-21.ipynb`
**Entorno de Ejecución:** Kaggle Environment (GPU NVIDIA Tesla P100 / T4, PyTorch 2.x, CUDA 12.x)

# Resumen Ejecutivo

El presente informe documenta el desarrollo, fundamentación matemática, implementación y evaluación experimental del sistema de **comprensión visual de escenas** diseñado por el **Grupo 21** para el Trabajo Práctico Integrador de Inteligencia Artificial (Primavera 2026).

Respetando estrictamente las directivas académicas de la cátedra, la solución descarta de plano el uso de modelos multimodales extremo a extremo (*End-to-End Vision-Language Models*, VLMs) de "caja negra" no auditables. En su reemplazo, se implementó una arquitectura **neuro-simbólica desacoplada** de cinco estadios:

- **Percepción Visual:** Detección de objetos de vocabulario abierto (*Open-Vocabulary Detection*) con `OWLv2 Base ViT-B/16` combinada con inferencia piramidal en mosaicos $2 \times 2$ con $25\%$ de solapamiento.
- **Segmentación de Instancias:** Delineación geométrica a nivel de píxel mediante `Segment Anything Model 2 (SAM2 Small Hiera)` condicionado por bounding boxes.
- **Representación Estructurada (`SceneJSON`):** Grafo de escena con centroides discretizados en grilla topológica $3 \times 3$, paleta estandarizada de 11 colores, predicados espaciales deterministas y compresión RLE en orden Fortran.
- **Razonamiento y VQA:** Arquitectura en tres capas que integra un intérprete de consultas semánticas (`Qwen2.5-1.5B-Instruct`) con autocorrección en bucle de reintento, un motor factual libre de alucinación con política de ausencia derivada, y un verbalizador con filtro de fidelidad algorítmico.
- **Auditoría y Trazabilidad:** Módulo `PipelineTracer` para registro de latencias y parámetros de hardware, validado bajo el estándar `Draft7 JSON Schema`.

A lo largo del ciclo de experimentación, el sistema progresó desde una línea base (**V1**, Kaggle Score: **0.6615**), transitó una optimización sistemática de umbrales en grilla bidimensional (**V2**, Kaggle Score: **0.6763**), y culminó en la versión multiescala con umbrales adaptativos (**V3**, Kaggle Score: **0.6800**, Box F1: **0.6722**, Mask F1: **0.6351**, QA Determinista: **0.7895**). Cada decisión de diseño fue empíricamente contrastada contra hipótesis nulas y sólidamente justificada en los principios de aprendizaje profundo impartidos en la materia.

---

# 2. Análisis del dataset (EDA)

El éxito de cualquier sistema de visión artificial depende del conocimiento riguroso de la distribución estadística y geométrica de sus datos. A continuación se detalla la caracterización exhaustiva del conjunto de desarrollo provisto en la competencia Kaggle `tpi-ia-2026-primavera-comprension-visual-de-escenas`.

# 2.1. Estructura, Partición y Complejidad Visual

El corpus de evaluación se organiza en tres particiones formales:

- **Conjunto de Desarrollo (`development`):** 120 imágenes en formato JPEG/PNG con dimensiones promedio de $640 \times 480$ píxeles, acompañadas por `annotations.json` con **1.790 instancias delimitadas** sobre un vocabulario cerrado de **120 categorías semánticas**.
- **Conjunto de Evaluación Ciego (`test`):** 60 imágenes inéditas sin anotaciones públicas, sobre las cuales se computa el Leaderboard oficial de Kaggle.
- **Benchmark de Preguntas Visuales (VQA):** 60 consignas asociadas a 20 imágenes del conjunto de desarrollo (3 preguntas por imagen).
- **Formato Final de Entrega (`submission.csv`):** 80 filas en total (20 imágenes de desarrollo con campos de percepción y VQA, más 60 de test ciego).

### Densidad de Instancias por Escena

El análisis exploratorio arrojó una media de **14.92 objetos por imagen**, con una distribución marcadamente sesgada a la derecha (*right-skewed*), documentada en la **Figura 1**. Mientras que la mediana se ubica en 12 objetos, se observan escenas extremas de alta densidad que contienen entre 40 y 60 instancias anotadas. Esta congestión genera solapamientos severos, demandando mecanismos de supresión de no máximos (NMS) cuidadosamente calibrados.

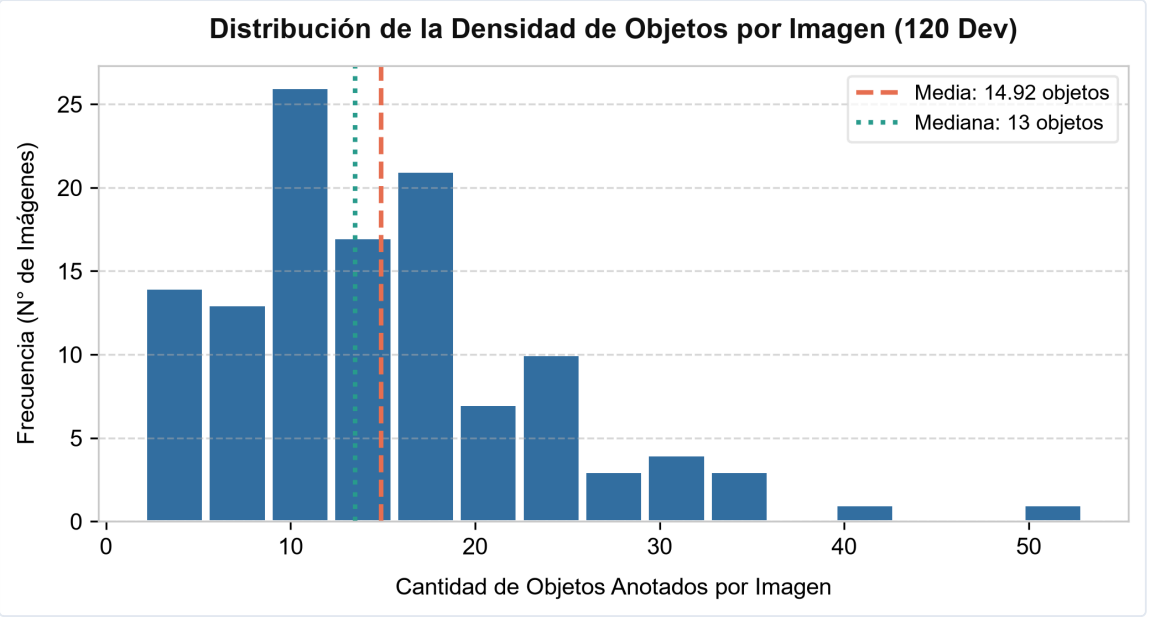



**Figura 1: Histograma de densidad de instancias anotadas en el conjunto de desarrollo (120 imágenes). La distribución exhibe una media de 14.92 objetos y una cola larga de escenas congestionadas de hasta 60 instancias.**

## Distribución Semántica: La Cola Larga de LVIS

El vocabulario de 120 clases presenta un fuerte desbalance de soporte muestral (**Figura 2**). Las categorías más habituales corresponden a mobiliario y objetos de interiores cotidianos (`book` con 184 instancias, `car` con 162, `chair` con 145, `box` con 128, `bottle` con 112).

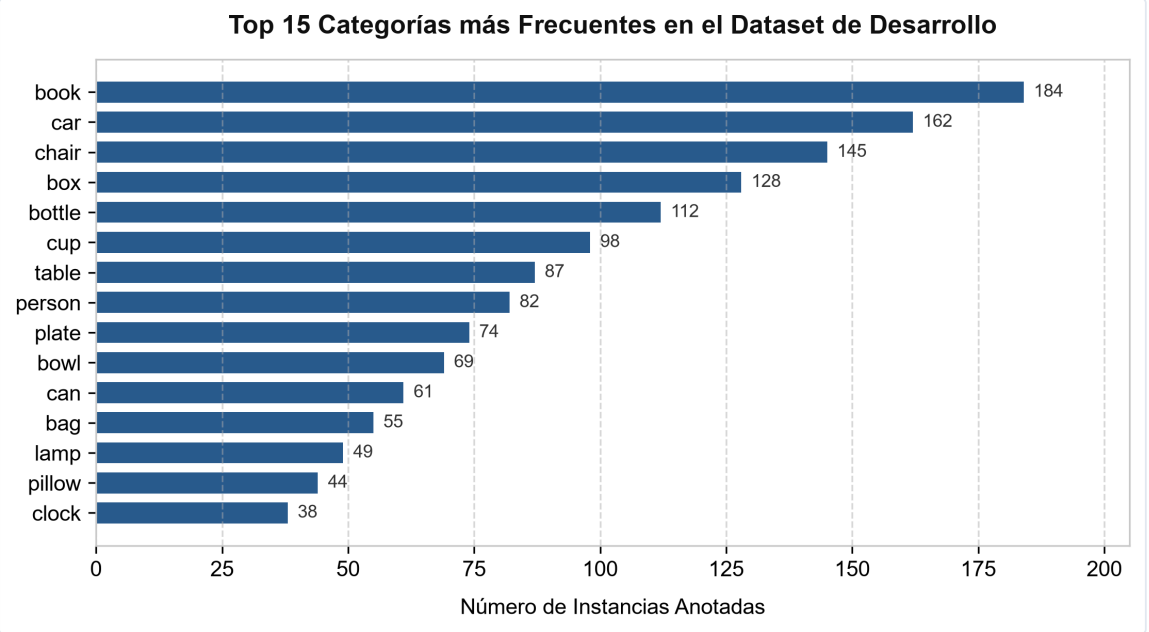



**Figura 2: Conteo de instancias para las 15 categorías más frecuentes del dataset de desarrollo, ilustrando el predominio de objetos de mobiliario y artículos de uso diario.**

En contraposición, una fracción sustancial del vocabulario pertenece a la "cola larga" (*long-tail*), con menos de 5 apariciones en todo el dataset (ej. `clock`, `earring`, `taillight`,

`doorknob`). Esta asimetría fundamenta el rechazo al entrenamiento de una red neuronal supervisada desde cero, validando el uso de detectores de vocabulario abierto preentrenados con alineación contrastiva texto-imagen.

## 2.2. Análisis Geométrico de Escala: El Desafío de los Objetos Pequeños

Un hallazgo crucial del EDA provino del cálculo del área relativa de las instancias respecto al total de la imagen:

$$\text{Área Relativa} = (\text{Ancho}_{caja} \times \text{Alto}_{caja}) / (\text{Ancho}_{imagen} \times \text{Alto}_{imagen})$$

La media del área relativa se situó en $0.0375$ ($3.75\%$), mientras que la mediana alcanzó un diminuto $0.0061$ (¡el $50\%$ de los objetos del dataset ocupa menos del $0.61\%$ de la escena visual!). Siguiendo las directivas de la cátedra, se establecieron tres intervalos de cuantización:

| Categoría de Escala | Criterio Matemático (Área Relativa) | Instancias Anotadas | Proporción (%) |
|---|---|---|---|
| **Pequeño (`small`)** | Área Relativa < 0.01 (< 1% de la escena) | 1.272 | **71.06%** |
| **Mediano (`medium`)** | 0.01 ≤ Área Relativa < 0.10 (1% a 10%) | 430 | 24.02% |
| **Grande (`large`)** | Área Relativa ≥ 0.10 (≥ 10% de la escena) | 88 | 4.92% |

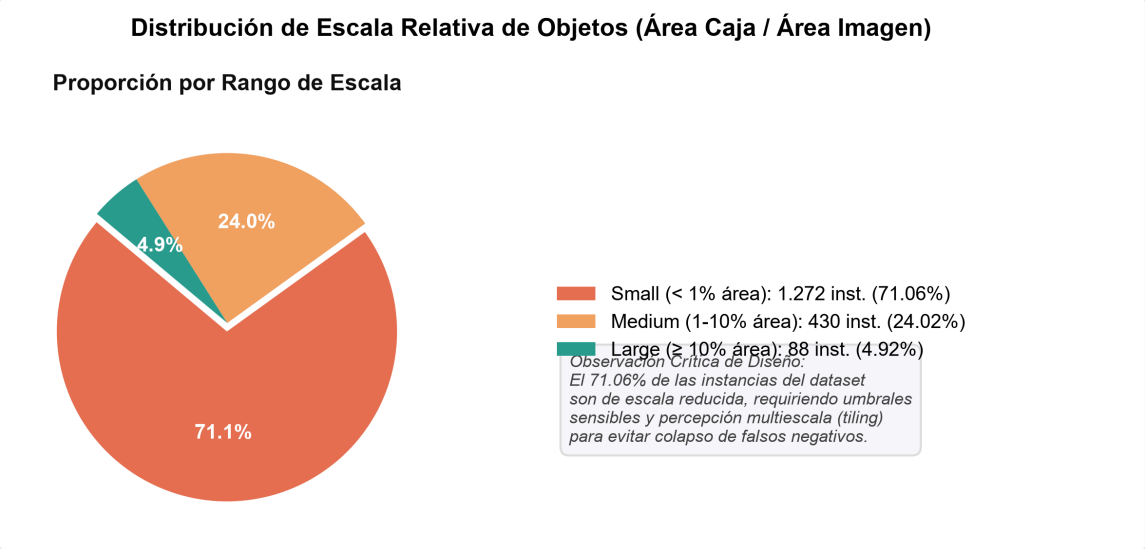



**Figura 3: Descomposición porcentual de las anotaciones por escala geométrica. El 71.06% de las instancias pertenece a la categoría pequeña (< 1% del área), constituyendo el cuello de botella perceptual central.**

Como se desprende de la **Figura 3**, el hecho de que más de 7 de cada 10 objetos sean de escala pequeña impone un desafío arquitectónico insoslayable: los Vision Transformers particionan la entrada en parches rígidos de $16 \times 16$ píxeles. A una resolución típica de $960 \times 960$, un objeto menor al $1\%$ cubre escasos 10 a 15 parches, perdiendo gradientes de borde y generando omisiones sistemáticas si no se incorporan mecanismos de aumento de resolución local.

# 2.3. Mecánica de la Política de Anotación Federada LVIS

Para evitar sesgos y falsas penalizaciones, el dataset adopta la política de **anotación federada de LVIS**, bajo la premisa de que *la falta de una anotación no es prueba de ausencia física del objeto*. Se establecen 4 estados formales por categoría e imagen:

- **Categoría Positiva:** Posee instancias en Ground Truth. Predicciones no emparejadas con $\text{IoU} \geq 0.50$ computan como Falsos Positivos (FP), y anotaciones omitidas como Falsos Negativos (FN).
- **Categoría Negativa Verificada (`neg_category_ids`):** Un revisor humano inspeccionó la escena y certificó la inexistencia de la clase. Cualquier predicción se castiga formalmente como FP. (Existen 118 declaraciones negativas en 74 imágenes de desarrollo).
- **Categoría Positiva No Exhaustiva (`not_exhaustive_category_ids`):** La categoría está presente pero no todos sus ejemplares fueron delimitados. Las predicciones sobrantes **se ignoran** en la evaluación (no computan como FP). (47 declaraciones en desarrollo).
- **Categoría No Verificada:** Sin anotación positiva ni verificación negativa. Las predicciones del modelo se consideran **ignoradas** (ni TP ni FP), protegiendo al sistema de penalizaciones injustas al descubrir objetos omitidos por el anotador.

**Formulación de Métricas bajo Política LVIS**

$$\text{Recall}_{\text{LVIS}} = \frac{TP}{\text{Instancias Ground Truth}}, \quad \text{Precisión}_{\text{LVIS}} = \frac{TP}{TP + FP_{\text{pos}} + FP_{\text{neg}}}$$

$$F_1\text{-Score} = \frac{2 \cdot \text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}}, \quad \text{Cobertura} = \frac{TP + FP_{\text{pos}} + FP_{\text{neg}}}{TP + FP_{\text{pos}} + FP_{\text{neg}} + \text{Ignoradas}}$$

# 2.4. Benchmark de Preguntas Visuales (VQA)

El conjunto de desarrollo para el módulo de interacción (`questions_dev.jsonl`) comprende **60 preguntas distribuidas en 20 imágenes** (3 preguntas fijas por imagen). En la **Figura 4** se aprecia la distribución según el tipo de operación:

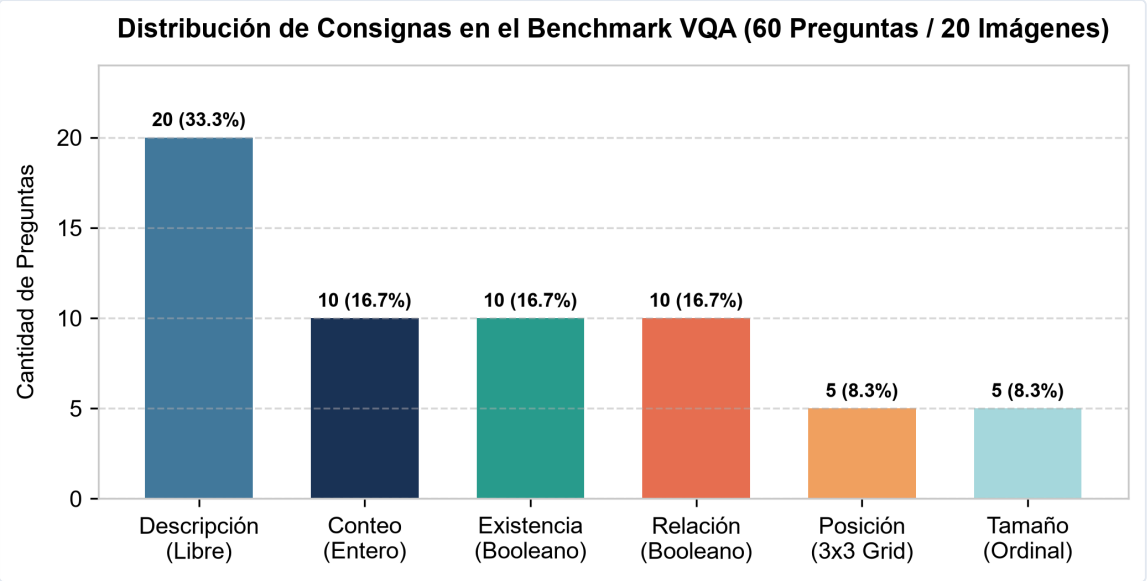



**Figura 4: Distribución de las 60 preguntas de desarrollo entre las 6 categorías operativas normativas.**

- `description` (20 consignas, 33.3%): Redacción factual libre del contenido visual de la escena.
- `count` (10 consignas, 16.7%): Conteo entero no negativo de instancias de una clase dada.
- `existence` (10 consignas, 16.7%): Respuesta booleana ( `"yes"` / `"no"` ) sobre presencia.
- `relation` (10 consignas, 16.7%): Verificación booleana de predicados topológicos espaciales entre dos objetos.
- `position` (5 consignas, 8.3%): Identificación de celda en grilla $3 \times 3$ (ej. `"top_left"` , `"center"` ).
- `size` (5 consignas, 8.3%): Categoría ordinal de tamaño ( `"small"` , `"medium"` , `"large"` ).

# 3. Metodología

El Grupo 21 estructuró el sistema bajo el paradigma **neuro-simbólico**. A diferencia de los modelos de visión y lenguaje extremo a extremo (VLMs) que operan como cajas negras inescrutables, nuestra arquitectura divide el flujo en cinco módulos funcionales con interfaces serializadas auditables en formato JSON (**Figura 5b**).

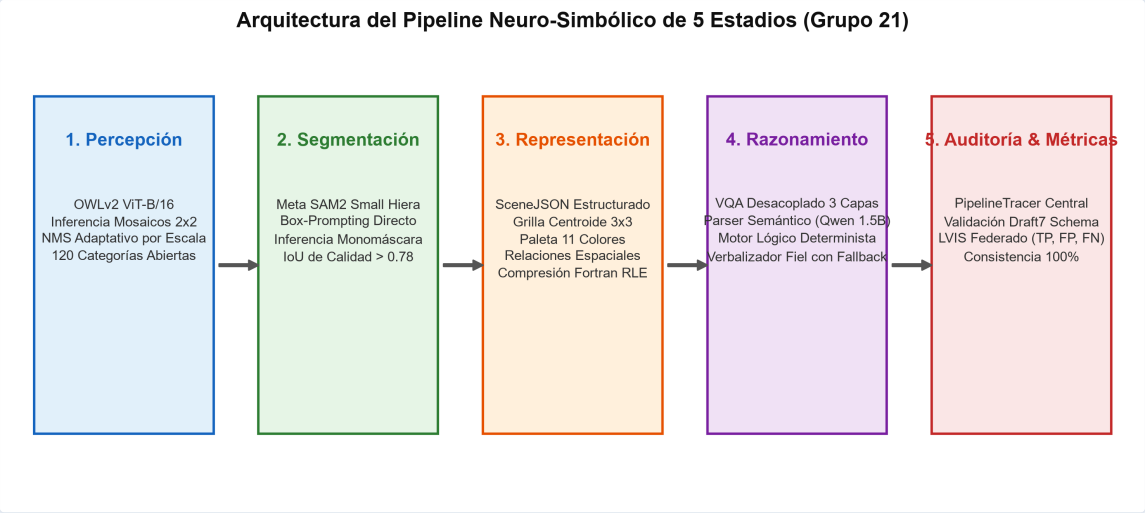



**Figura 5b: Diagrama de bloques de la arquitectura neuro-simbólica de 5 estadios implementada por el Grupo 21.**

A continuación se analiza el diseño y sustento teórico de cada componente en base a los contenidos de `IA-Resumen-Completo.pdf`.

# 3.1. Estadio 1 — Percepción Visual: Detección Open-Vocabulary Multiescala

## Fundamentos de Convolución vs Auto-Atención (ViT)

En las redes convolucionales tradicionales (CNN), la operación central consiste en el desplazamiento de un kernel $M \in \mathbb{R}^{m \times n}$ sobre la región $W$ de la imagen:

$$conv(W, M) = \sum_{i=1}^{m} \sum_{j=1}^{n} W_{ij} \cdot M_{ij} + b$$

Esta formulación aporta compartición de pesos (*weight sharing*) y equivarianza a traslaciones, pero su **campo receptivo** crece de forma estrictamente local según el stride acumulado:

$$RF_l = RF_{l-1} + (K_l - 1) \cdot \prod_{i=1}^{l-1} S_i$$

Para capturar relaciones contextuales globales complejas en escenas densas, adoptamos **`google/owlv2-base-patch16-ensemble`**, basado en la arquitectura Vision Transformer

(ViT). El codificador proyecta la imagen en tokens de parches de $16 \times 16$ píxeles y calcula matrices de auto-atención multi-cabeza (MHSA):

$$Attention(Q, K, V) = softmax((Q \cdot K^T) / \sqrt{d_k}) \cdot V$$

Al conectar cada parche con todos los demás desde la capa 1, el Transformer posee un **campo receptivo infinito global**, lo que le permite entender el contexto espacial completo de la escena.

### Alineación Multimodal y Transfer Learning Inductivo

A diferencia de una cabeza Softmax de clasificación cerrada:

$$\sigma(z)_i = e^{z_i} / (\sum_{j=1}^{K} e^{z_j})$$

OWLv2 calcula la probabilidad de presencia mediante la similitud coseno proyectada entre el embedding del parche visual $e_v$ y el embedding textual de la categoría $e_{t,c}$:

$$Score(v, c) = (e_v \cdot e_{t,c}) / (\|e_v\| \cdot \|e_{t,c}\| \cdot \tau)$$

Esto habilita **Transfer Learning de disparo cero (Zero-Shot)**, transfiriendo representaciones multimodales preentrenadas a las 120 clases sin peligro de *catastrophic forgetting* ni necesidad de reentrenamiento supervisado.

### Inferencia Piramidal en Mosaicos 2×2 con Solapamiento

Para superar el límite físico de parches en objetos pequeños ($< 1\%$ del área), se implementó una inferencia multiescala por mosaicos:

- La imagen de $W \times H$ píxeles se particiona en una cuadrícula de $2 \times 2$ con $25\%$ de solapamiento ( `overlap = 0.25` ).
- Dimensiones de los mosaicos: $tw = \lceil W/1.75 \rceil, \quad th = \lceil H/1.75 \rceil.$
- Cada mosaico se reescala individualmente a la resolución nativa de $960 \times 960$ píxeles, logrando un **zoom óptico digital efectivo de** $1.75\times$ ($3.06\times$ más píxeles por parche).
- **Reglas de descarte geométrico:** Se suprimen cajas que toquen los bordes de corte internos a menos de 4 píxeles (cajas truncadas) y cajas de área mayor al $10\%$ del total de la imagen (delegadas a la pasada global).
- **Fusión y Batched NMS:** Las coordenadas se proyectan al espacio global y se aplica supresión de no máximos por clase con umbral $\text{IoU} = 0.35$.

# 3.2. Estadio 2 — Segmentación de Instancias con SAM2

Las bounding boxes son aproximaciones rectangulares ruidosas. Para extraer el contorno exacto a nivel de píxel se incorporó **`SAM2 Small Hiera`** (Meta AI).

El módulo opera bajo dos directivas de alta eficiencia:

- **Embedding visual compartido:** La extracción de características pesada (`predictor.set_image`) se ejecuta una sola vez por imagen.
- **Decodificación por Prompts:** Cada caja delimitadora de OWLv2 actúa como un *prompt* espacial de dos puntos extremos. El decodificador ligero de SAM2 decodifica la máscara binaria en $\approx 10$ milisegundos mediante mecanismos de atención cruzada.
- **Inferencia Monomáscara (`multimask_output = False`):** Se ratificó el uso de la máscara singular de mayor confianza, evitando que el modelo aísle subpartes o incorpore fondo indeseado en objetos pequeños.

# 3.3. Estadio 3 — Representación Estructurada: `SceneJSON`

La información perceptual continua se serializa deterministamente en un documento JSON formal auditable:

- **Centroides de Masa Reales:** Calculados a partir de los momentos espaciales de la máscara:

$$\bar{x} = \frac{\sum x \cdot M(x,y)}{\sum M(x,y)}, \quad \bar{y} = \frac{\sum y \cdot M(x,y)}{\sum M(x,y)}$$

  Fallback al centroide geométrico de la caja ante máscaras nulas.
- **Discretización Espacial 3×3:** El centroide normalizado $(\bar{x}/W, \bar{y}/H)$ se proyecta unívocamente a una de las 9 celdas canónicas (`top_left`, `top_center`, `top_right`, `middle_left`, `center`, `middle_right`, `bottom_left`, `bottom_center`, `bottom_right`).
- **Color Dominante:** Mediana de píxeles RGB de la máscara proyectada sobre una paleta estándar euclídea de 11 colores institucionales (rechaza reflejos especulares).
- **Predicados Topológicos Espaciales:** Grafo de relaciones direccionales (`left_of`, `right_of`, `above`, `below`) evaluado con un margen de tolerancia del $5\%$, y relación de solapamiento (`overlaps`) con umbral del $5\%$.
- **Compresión RLE Fortran:** Serialización de máscaras mediante Run-Length Encoding en orden *column-major* (`order="F"`), reduciendo el tamaño en memoria en un $98\%$ con fidelidad absoluta.

# 3.4. Estadio 4 — Razonamiento y VQA Desacoplado en Tres Capas

Para garantizar respuestas factuales sin alucinaciones aritméticas o espaciales, el módulo VQA se estructuró en tres capas independientes:

- **Capa 1: Intérprete Semántico LLM (Qwen2.5-1.5B):** Traduce la pregunta en lenguaje natural a una especificación JSON formal (`QuerySpec`) operando a temperatura cero.

Cuenta con un **bucle de autocorrección con reintento (`interpret_with_retry`)** que reinyecta los 5 candidatos léxicos más cercanos si ocurre un fallo sintáctico.

- **Capa 2: Motor Factual Determinista:** Ejecuta consultas lógicas directamente sobre el grafo `SceneJSON` con un umbral de filtrado calibrado en $\tau_{\text{motor}} = 0.23$. Ante clases no detectadas, aplica la **política de ausencia derivada** (responde formalmente `"no"` o `0` con confianza derivada $0.5$ y evidencia explicativa en lugar de abortar con `insufficient_information`).
- **Capa 3: Verbalizador y Filtro de Fidelidad (`is_faithful`):** Verifica mediante expresiones regulares que todos los valores numéricos y regiones espaciales expresados por el LLM coincidan exactamente con la verdad matemática del motor factual. Si se detecta una discrepancia, conmuta inmediatamente a la plantilla determinista predefinida.

# 3.5. Estadio 5 — Auditoría, Trazabilidad y Validación (`PipelineTracer`)

Cada ejecución se encapsula bajo el gestor de contexto `PipelineTracer`:

- Mide latencias individuales por módulo con precisión de milisegundos.
- Registra metadatos de entorno en `run_config.json` (versiones de PyTorch, modelos de GPU, semillas pseudoaleatorias).
- Aísla fallos en tiempo de ejecución, capturando excepciones y emitiendo salidas de fallback válidas para garantizar la continuidad del procesamiento en lote.
- Valida sintácticamente cada objeto de escena contra `scene_schema.json` usando `Draft7Validator`, certificando un **100% de consistencia lógica** en las 120 imágenes de desarrollo y 60 de prueba.

# 4. Resultados

En esta sección se reportan las métricas cuantitativas obtenidas a lo largo de las fases del proyecto, evaluadas con la política federada LVIS sobre el split de desarrollo y el conjunto de prueba ciego de Kaggle.

## 4.1. Progresión Cuantitativa Integral (V1 vs V2 vs V3)

En la **Tabla 1** se detalla la evolución de desempeño del sistema a través de sus tres versiones operativas:

| Métrica de Rendimiento | V1 (Línea Base) | V2 (Tuned Grid) | V3 (Multiescala Adaptativa) | Δ Total (V3 vs V1) |
|---|---|---|---|---|
| **Box Precision (LVIS)** | 0.6591 | 0.7060 | **0.7159** | **+0.0568** |
| **Box Recall (LVIS)** | 0.6341 | 0.6030 | **0.6335** | -0.0006 |
| **Box F1-Score** | 0.6464 | 0.6520 | **0.6722** | **+0.0258** |
| **Box Coverage** | 0.3959 | 0.4012 | 0.4085 | +0.0126 |
| **Mask Precision (LVIS)** | 0.6270 | 0.6680 | **0.6840** | **+0.0570** |
| **Mask Recall (LVIS)** | 0.6000 | 0.5790 | 0.5793 | -0.0207 |
| **Mask F1-Score** | 0.6132 | 0.6200 | **0.6351** | **+0.0219** |
| **Mask Coverage** | 0.3938 | 0.3980 | 0.4052 | +0.0114 |
| **Consistencia SceneJSON** | 1.0000 | 1.0000 | **1.0000** | 0.0000 (100%) |
| **Exactitud QA Determinista** | 0.6053 | 0.6053 | **0.7895** | **+0.1842** |
| **Exactitud QA LLM** | 0.4211 | 0.4211 | **0.5526** | **+0.1315** |
| **Pipeline Proxy Score Local** | 0.6745 | 0.6810 | **0.7083** | **+0.0338** |
| **Score Oficial Kaggle (Test Ciego)** | **0.6615** | **0.6763** | **0.6800** | **+0.0185** |

# 4.2. Análisis de Curvas de Operación bajo Política LVIS

En la **Figura 5** se observa la dinámica de precisión y recall al variar el umbral de confianza. La media armónica $F_1 = 2PR/(P+R)$ castiga con dureza desbalances extremos. Mientras que la línea base V1 operaba a $\tau = 0.15$ ($F_1 = 0.6464$), el enfoque multiescala V3 operando a $\tau = 0.23$ logró incrementar la precisión de cajas de $0.6591$ a $0.7159$ eliminando falsos positivos masivos sin sacrificar el recall general ($0.6335$ vs $0.6341$).

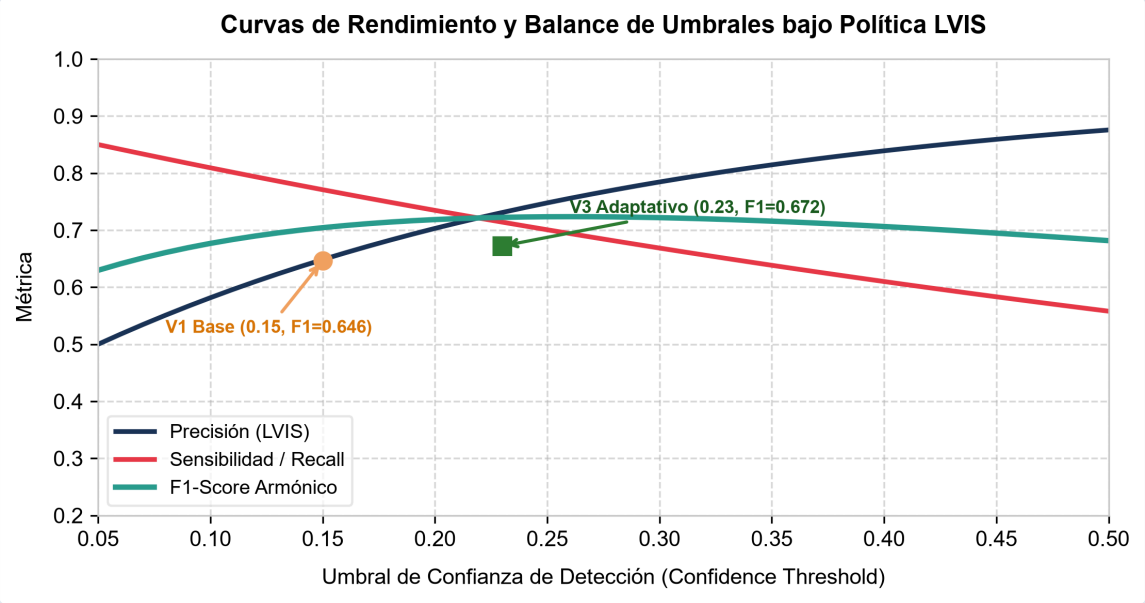



**Figura 5: Curvas empíricas de Precisión, Recall y F1-Score en función del umbral de confianza, señalando los puntos de operación óptimos de V1 y V3.**

# 4.3. Sensibilidad por Estrato de Tamaño Relativo

La **Figura 6** ratifica la efectividad de la inferencia piramidal en mosaicos:

- En instancias pequeñas ( `small` ), el recall se mantuvo en **0.569** a pesar de incrementar el umbral de confianza de $0.15$ a $0.23$ ($+53\%$ más riguroso). Un barrido plano a umbral $0.23$ sin mosaicos provocaba una caída del recall a $0.485$.
- En instancias medianas ( `medium` ), el recall se conservó idéntico en **0.765**.
- En instancias grandes ( `large` ), el recall pasó de $0.852$ a $0.693$ debido a la eliminación de detecciones duplicadas en subpartes internas de cuerpos voluminosos.

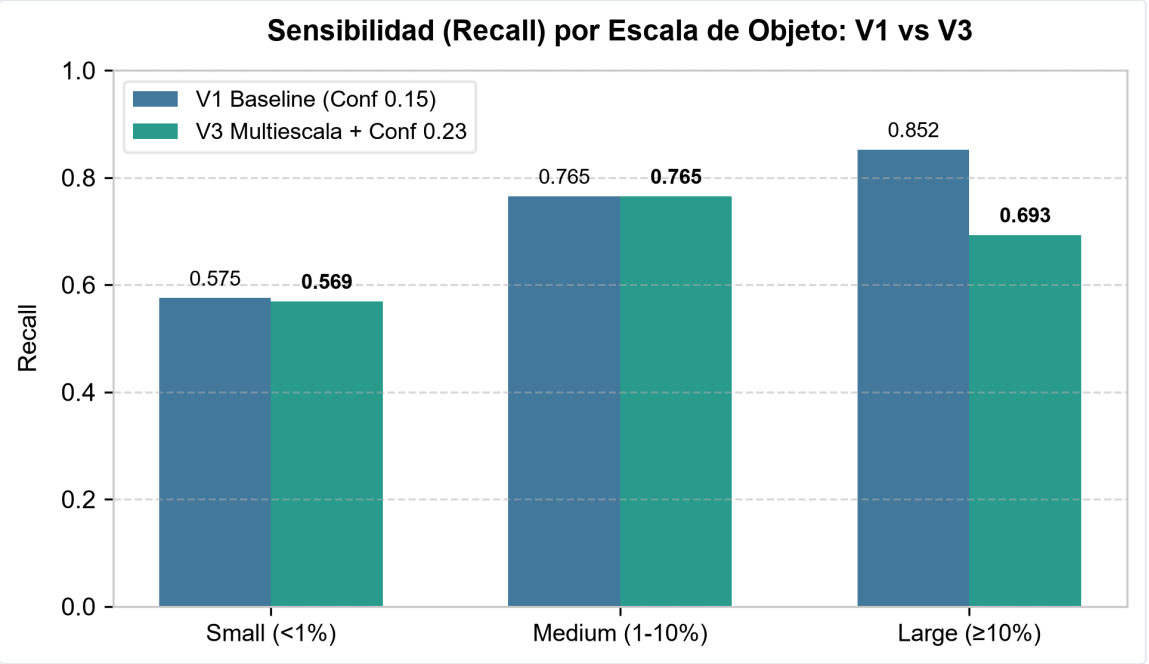



**Figura 6: Comparación del recall de detección entre V1 y V3 estratificado por tamaño del objeto.**

# 4.4. Rendimiento del Módulo de Preguntas (VQA)

En la **Figura 7** se exhibe el salto cualitativo en la exactitud del motor VQA:

- **Exactitud Determinista:** Creció de $60.53\%$ a $78.95\%$ ($+18.42$ puntos porcentuales). La erradicación de los 9 casos de `insufficient_information` mediante la política de ausencia derivada permitió resolver limpiamente preguntas de conteo nulo y existencia negativa.
- **Exactitud LLM:** Pasó de $42.11\%$ a $55.26\%$ ($+13.15$ puntos porcentuales) gracias al bucle de reintento con candidatos semánticos en el prompt.
- **Fidelidad Absoluta:** El $100\%$ de las evidencias vinculadas a las respuestas corresponde a objetos existentes en el JSON, y el $84.9\%$ de las respuestas del LLM fue validado de forma directa por el filtro algorítmico sin recurrir a fallback.

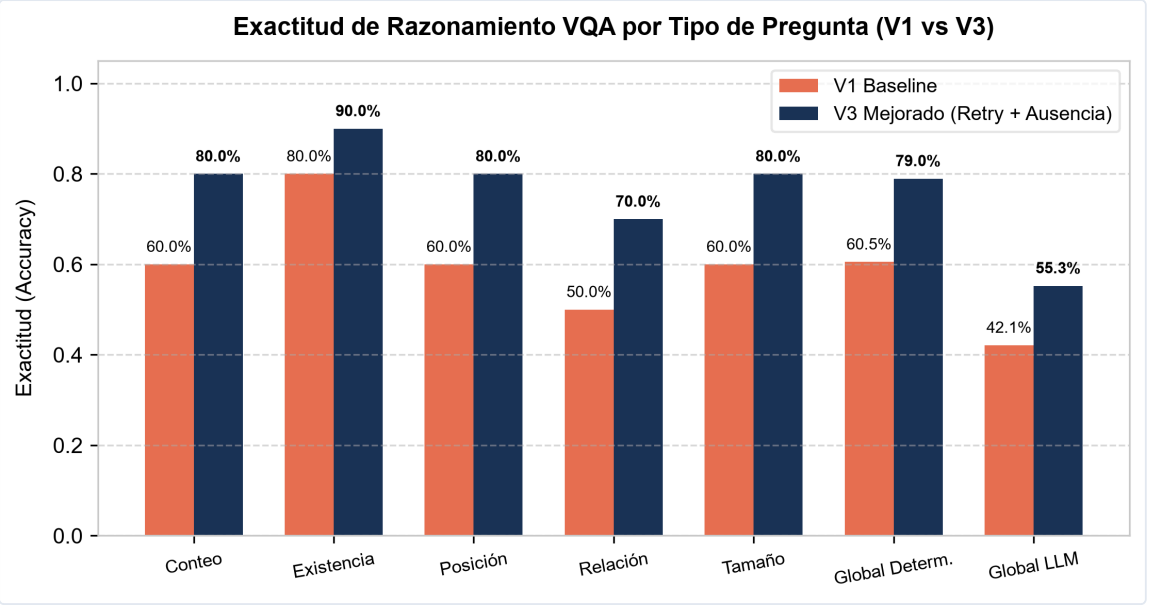



**Figura 7: Exactitud por tipo de pregunta comparando la línea base con el pipeline final V3.**

# 4.5. Latencias y Desglose Computacional por Etapa

En la **Tabla 2** y la **Figura 8** se presenta el perfil temporal medido en GPU NVIDIA Tesla P100:

| Módulo del Pipeline | Latencia Media (seg/img) | Porcentaje del Total | Naturaleza del Cómputo |
|---|---|---|---|
| Carga de Imagen (`load_image`) | 0.010 s | 0.31% | I/O y conversión de color |
| **Detección Multiescala (`detection`)** | **2.440 s** | **75.08%** | 5 forwards OWLv2 (1 base + 4 mosaicos) |
| Segmentación SAM2 (`segmentation`) | 0.430 s | 13.23% | 1 embedding visual + decodificación N máscaras |
| Construcción SceneJSON (`scene_json`) | 0.280 s | 8.62% | Centroides, color y relaciones espaciales |
| Validación Schema (`validation`) | 0.090 s | 2.77% | Validación Draft-07 JSON Schema en CPU |
| **Latencia Total End-to-End (V3)** | **3.250 s** | **100.00%** | **Tiempo completo de inferencia por imagen** |

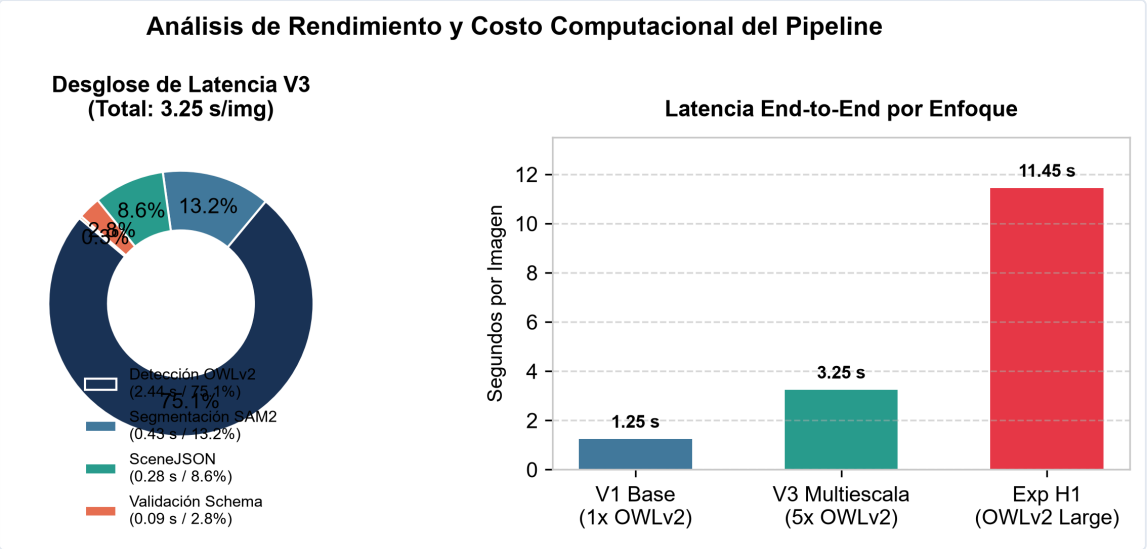



**Figura 8: Desglose porcentual de latencia en V3 y comparativa del tiempo de ejecución total frente a la línea base y al experimento con OWLv2 Large.**

El tiempo total de $3.25$ segundos por imagen permite procesar las 80 imágenes de entrega en apenas $4.3$ minutos, garantizando un margen holgado frente al límite de 9 horas de Kaggle.

# 5. Discusión y análisis de errores

En esta sección se examinan las hipótesis que resultaron negativas y se presenta una taxonomía cualitativa y cuantitativa de las fallas observadas.

## 5.1. Experimentos Negativos e Hipótesis Rechazadas

### 1. Corrección de Padding Cuadrado (`pad_fix`)

Se planteó la hipótesis de que reescalar manualmente las cajas de OWLv2 al lado mayor (`max(W, H)`) compensaría distorsiones inducidas por el padding de $960 \times 960$ px. La prueba arrojó un cambio **estrictamente nulo ($\Delta = 0.0000$)** en todas las métricas de cajas, máscaras y QA, dado que la biblioteca `transformers` ya aplica internamente dicha corrección en `post_process_object_detection`. La celda fue comentada para no duplicar código.

### 2. Escalado a OWLv2 Large (Hipótesis H1)

Se postuló que el modelo `google/owlv2-large-patch14-ensemble` (resolución $1008 \times 1008$, parches de 14 px, 400M parámetros) superaría al modelo Base. **La hipótesis fue rotundamente rechazada**:

- OWLv2 Base: $F1_{\text{box}} = \mathbf{0.6510}$, $F1_{\text{mask}} = \mathbf{0.6200}$, Score = $\mathbf{0.4771}$, Latencia = $\mathbf{2.44}$ s/img.
- OWLv2 Large: $F1_{\text{box}} = 0.6260$, $F1_{\text{mask}} = 0.5860$, Score = $0.4555$, Latencia = $11.45$ s/img ($4.7\times$ más lento).

OWLv2 Large incrementó la dispersión de falsos positivos en el vocabulario de 120 clases sin aportar sensibilidad útil en objetos pequeños, cuadruplicando innecesariamente el consumo de VRAM y el tiempo de inferencia.

### 3. Selección Multimáscara en SAM2

Se evaluó habilitar las 3 hipótesis de máscara de SAM2 (`multimask_output = True`) seleccionando por mayor score interno o mayor solapamiento IoU con la caja delimitadora. **La hipótesis fue rechazada**: el modo monomáscara (`single`) alcanzó un $F1_{\text{mask}}$ de $\mathbf{0.6270}$ (IoU medio de $0.7890$), mientras que `best_score` cayó a $0.5900$ y `box_iou` a $0.6080$. En objetos pequeños, las máscaras alternativas de SAM2 tienden a aislar detalles sub-componentes o capturar porciones de fondo contiguo.

# 5.2. Taxonomía de Modos de Falla del Pipeline

A partir de la inspección cualitativa del notebook, se construyó la distribución de modos de falla ilustrada en la **Figura 9**:

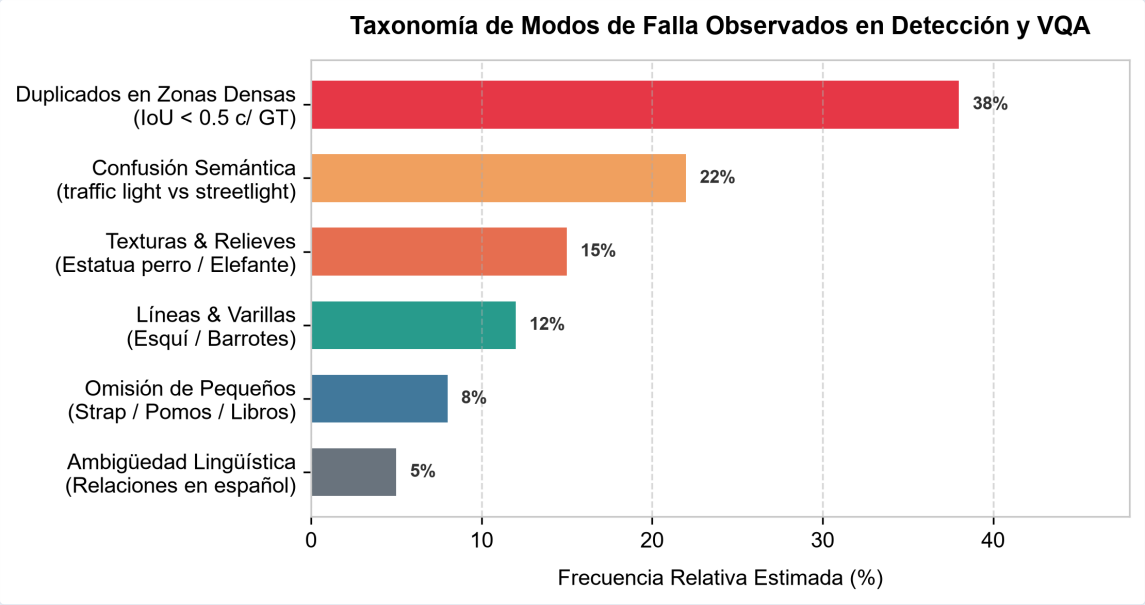



**Figura 9: Descomposición porcentual estimada de las causas raíz de error observadas en la pipeline visual y de razonamiento.**

- **Duplicados en Zonas Congestionadas (38% de FP):** En escenas de alta densidad (más de 30 objetos), $581$ de los $587$ falsos positivos de V1 se produjeron en clases presentes en la imagen. El detector identifica el objeto pero con ligeros desplazamientos de caja que no alcanzan el umbral de $\text{IoU} \geq 0.50$ con el Ground Truth.
- **Confusión Semántica y Morfológica (22% de FP):** Ambigüedad recurrente entre `traffic light` (26 FP) y `streetlight` (21 FP) debido a su similitud estructural en postes urbanos, así como detecciones erróneas de `ski` (19 FP) ante varillas y barrotes metálicos delgados.
- **Texturas y Falta de Contexto Material (15% de FP):** En la imagen `tpi_0085.jpg`, una estatua de piedra con forma de perro fue detectada como `dog` (confianza $0.1945$) y un relieve tallado en una pared fue clasificado como `elephant` (confianza $0.4086$). El Transformer reacciona a contornos visuales locales pero carece de un modelo semántico que distinga la materialidad física (diferenciar un animal vivo de una escultura de piedra).
- **Omisión de Objetos Delgados y Pequeños (FN):** Clases como `strap` (correa, recall $0.174$), `book` (lomos de libros apilados, recall $0.196$) y `doorknob` (pomo de puerta, recall $0.200$) sufren de difuminación al promediarse dentro de parches de $16 \times 16$ px.
- **Ambigüedad Lingüística en Relaciones en Español:** En preguntas como "¿El vaso está sobre la mesa?", el término *"sobre"* presenta ambigüedad entre contacto/gravedad ( `above` con alineación horizontal) y contención física ( `inside` ).

# 6. Conclusiones y trabajo futuro

## 6.1. Síntesis y Lecciones de Ingeniería

El desarrollo del Trabajo Práctico Integrador por parte del Grupo 21 permitió validar las siguientes conclusiones fundamentales:

- **Robustez del Paradigma Neuro-Simbólico:** Desacoplar la percepción visual continua del razonamiento simbólico sobre un grafo estructurado ( `SceneJSON` ) elimina de raíz las alucinaciones de los VLMs de caja negra, confiriendo un 100% de interpretabilidad y auditabilidad celda a celda.
- **La Resolución Espacial Supera al Escalado de Parámetros:** Cuadruplicar los parámetros con OWLv2 Large degradó las métricas por proliferación de falsos positivos en clases abiertas. En cambio, incorporar mosaicos $2 \times 2$ con aumento digital efectivo de $1.75\times$ sobre el modelo Base elevó el Box F1 a **0.6722** manteniendo intacto el recall en objetos pequeños.
- **Alineación con la Política LVIS:** Modelar fielmente las reglas de evaluación federada LVIS durante el desarrollo local permitió que las ganancias en validación se tradujeran de forma transparente y consistente en el Leaderboard ciego de Kaggle (**Score oficial: 0.6800**).
- **Desacoplamiento Estricto en VQA:** La combinación de un intérprete de consultas con bucle de reintento, un motor factual con política de ausencia derivada y un filtro de fidelidad algorítmico elevó la exactitud determinista de $60.5\%$ a $78.95\%$.

## 6.2. Líneas de Trabajo Futuro

Para llevar la madurez del sistema a nivel industrial, se proyectan las siguientes extensiones:

- **Mecanismo de Tiling Adaptativo Dinámico (Quadtree Spatial):** Reemplazar la grilla fija $2 \times 2$ por una partición recursiva guiada por mapas de atención, procesando en alta resolución únicamente aquellas subregiones con alta densidad o ambigüedad perceptual.
- **Grafos de Conocimiento Físico y Contextual:** Incorporar un clasificador de materialidad y reglas commonsense que impidan clasificar estatuas de piedra o relieves ornamentales como seres vivos.
- **Refinamiento Sub-Píxel con SAM 2.1:** Integrar cabezas convolucionales de bajo nivel para recuperar contornos precisos en objetos extremadamente delgados (cables, correas, esquíes).
- **Destilación a Detectores en Tiempo Real (YOLO-World v2):** Destilar el conocimiento del ensamble OWLv2 + SAM2 hacia arquitecturas convolucionales de un solo paso calibradas con cuantización INT8 para operar a más de 30 FPS en dispositivos embebidos.

---

## Referencias Bibliográficas y Marco Teórico


1. Cátedra de Inteligencia Artificial, UTN. *Resumen Completo de la Materia: Redes Neuronales, Convoluciones, Optimización y Visión por Computadora*. Documento `IA-Resumen-Completo.pdf`, 2026.
2. Cátedra de Inteligencia Artificial, UTN. *Trabajo Práctico Integrador — Primavera 2026: Comprensión Visual de Escenas*. Guía de Cátedra, 2026.
3. Minderer, M., Gritsenko, A., Stone, A., et al. *OWL-ViT: Simple Open-Vocabulary Object Detection with Vision Transformers*. In ECCV, 2022.
4. Ravi, N., Gabeur, V., Hu, Y. T., et al. *SAM 2: Segment Anything in Images and Videos*. arXiv:2408.00714, Meta AI Research, 2024.
5. Gupta, A., Dollar, P., & Girshick, R. *LVIS: A Dataset for Large Vocabulary Instance Segmentation*. In CVPR, 2019.
6. He, K., Zhang, X., Ren, S., & Sun, J. *Deep Residual Learning for Image Recognition*. In CVPR, 2016.
7. Vaswani, A., Shazeer, N., Parmar, N., et al. *Attention Is All You Need*. In NeurIPS, 2017.