Facultad Regional Córdoba

Cátedra de Inteligencia Artificial - 5K3A

TRABAJO PRÁCTICO INTEGRADOR - Reporte técnico - Segundo cuatrimestre

Docentes:

- García, Mario Alejandro
- Forte, Guillermo Omar
- Gramática, Martín Nicolás

Grupo N°4:

- Carrera, Sebastian - 82454
- Ferreyra, Diego - 50881
- Iril, Rocco Maciel - 90104
- Yacuzzi, Maximiliano - 66276

Fecha de entrega: 07/11/2025

Introducción

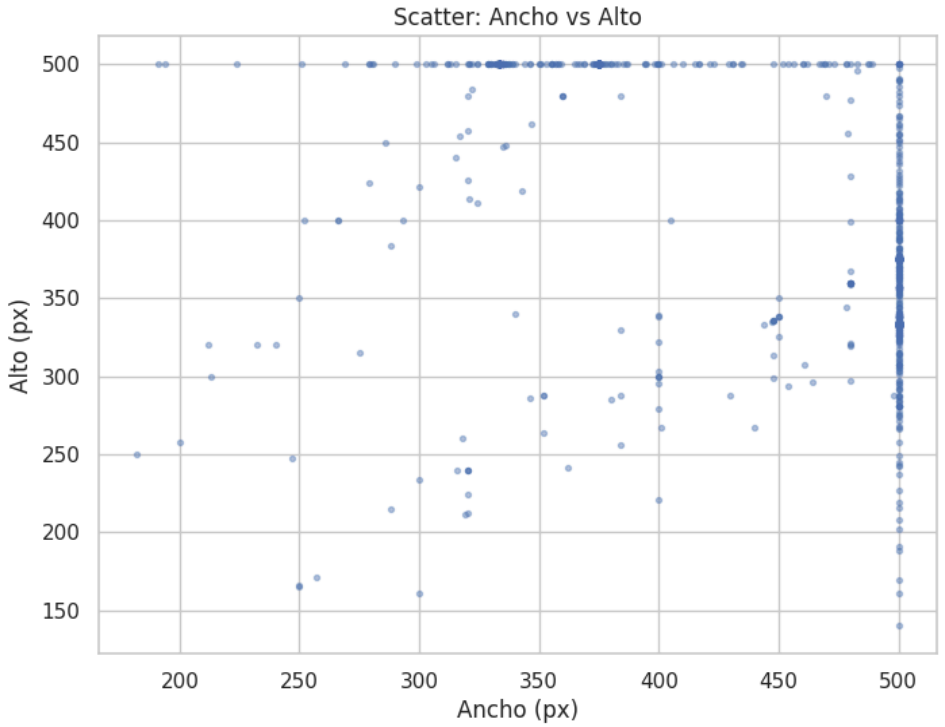
En este trabajo práctico se desarrollará un sistema de busqueda multimodal de imágenes mediante CLIP, FAISS y un LLM. Se comentará todo el trabajo desarrollado, las decisiones tomadas, los resultados obtenidos, las conclusiones a las que se llegaron y comentarios sobre las situaciones a las que el grupo se enfrentó durante el desarrollo.

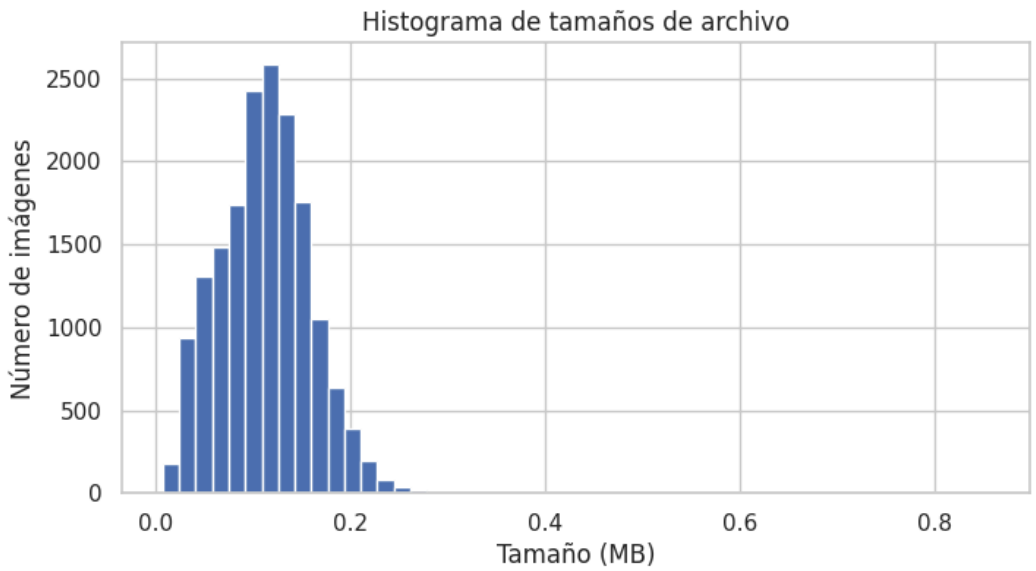
Análisis de dataset - EDA

El análisis de datos se separa en tres partes:

1. **Características de las imágenes como archivos**
    - Cantidad total de imágenes
    - Alto y ancho en pixeles
    - Peso en megabytes
    - Canales (Se esperan 3, que indica RGB, para trabajar con CLIP)

```
Total imágenes: 17125
Dimensiones (px) - ancho: min/max/mean 142 500 466.7975474452555
Dimensiones (px) - alto:  min/max/mean 71 500 389.5076204379562
Tamaño (MB) - min/max/mean: 0.007319 0.855251 0.11223457121167883
Canales únicos: {3: 17125}
```





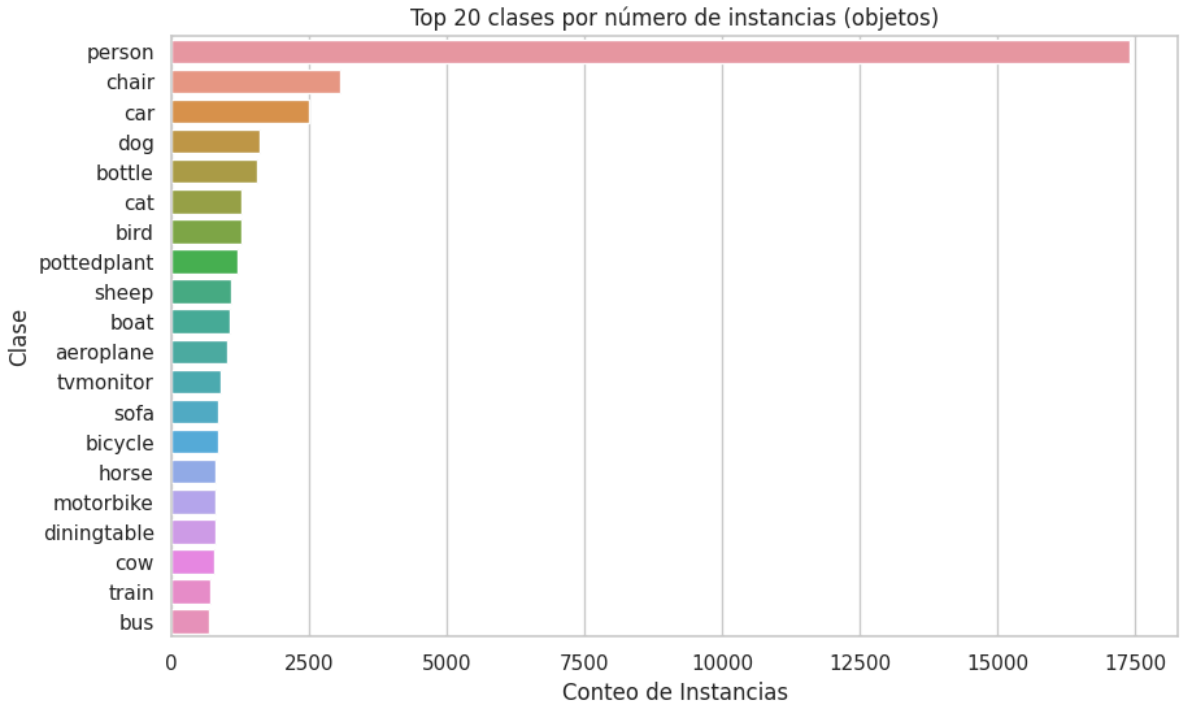
2. **Características del contenido de las imágenes a partir de anotaciones**
    - Objetos en imágenes
    - Conteo total de objetos en imágenes (Puede haber múltiples de un mismo objeto en una imagen)
    - Conteo de objetos de manera única por imagen

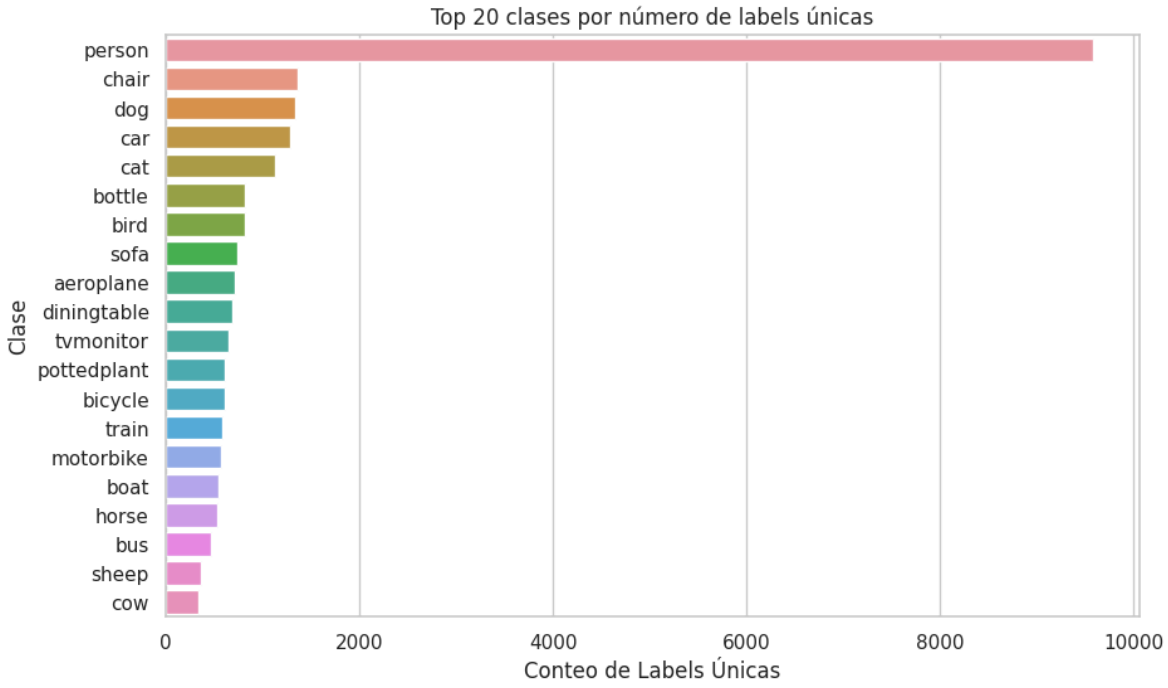
Conteo total de instancias de objetos

	instances
person	17401
chair	3056
car	2492
dog	1598
bottle	1561
cat	1277
bird	1271
pottedplant	1202
sheep	1084
boat	1059
aeroplane	1002
tvmonitor	893
sofa	841
bicycle	837
horse	803
motorbike	801
diningtable	800
cow	771
train	704
bus	685

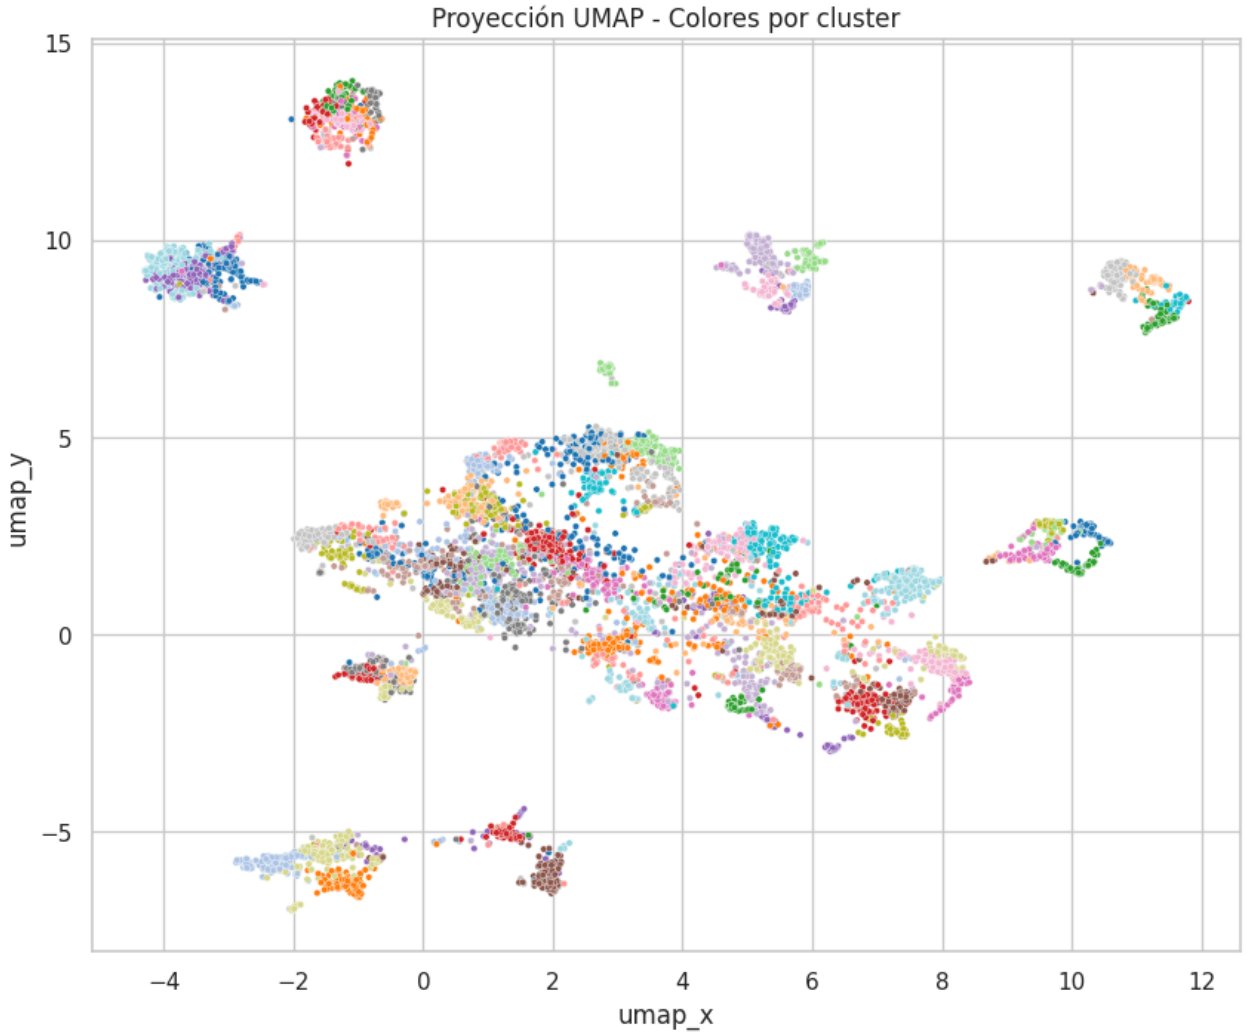
Conteo de labels únicas por imagen

	unique
person	9583
chair	1366
dog	1341
car	1284
cat	1128
bottle	812
bird	811
sofa	742
aeroplane	716
diningtable	691
tvmonitor	645
pottedplant	613
bicycle	603
train	589
motorbike	575
boat	549
horse	526
bus	467
sheep	357
cow	340


Top 20 clases por número de instancias (objetos)
person
chair
car
dog
bottle
cat
bird
pottedplant
sheep
boat
aeroplane
tvmonitor
sofa
bicycle
horse
motorbike
diningtable
cow
train
bus
Clase
0
2500
5000
7500
10000
12500
15000
17500
Conteo de Instancias


Top 20 clases por número de labels únicas
person
chair
dog
car
cat
bottle
bird
sofa
aeroplane
diningtable
tvmonitor
pottedplant
bicycle
train
motorbike
boat
horse
bus
sheep
cow
Clase
0
2000
4000
6000
8000
10000
Conteo de Labels Únicas

3. **Clusterización tras embeddings mediante K-Means y UMAP**
    - Gráficos de clusters con embeddings globales



4. Visualización rápida de imágenes por clase

Ejemplos para clase: person

2011_004733.jpg



2011_007001.jpg



2011_004451.jpg

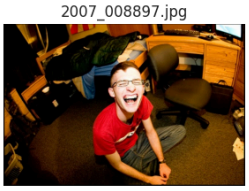


Ejemplos para clase: chair

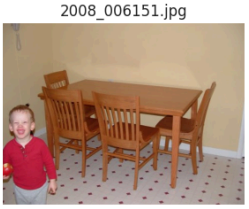
2008_006841.jpg



2007_008897.jpg



2008_006151.jpg



Ejemplos para clase: car

2010_002546.jpg



2011_000249.jpg

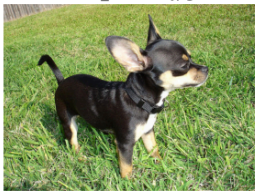


2009_001245.jpg



Ejemplos para clase: dog

2010_000082.jpg



2010_002586.jpg



2008_003511.jpg



Metodología

Se separará el flujo de trabajo en etapas y se dará información relevante de cada una.

Realizar embeddings de imágenes mediante CLIP.

Se realizaron los embedding con el modelo CLIP ViT-L-14, con los pesos entrenados por OpenAI.
Este modelo devuelve embeddings de 768 dimensiones, lo cual aporta más detalle en la representación semántica de las imágenes (Que otro modelo como ViT-B/32, que trabaja con 512 dimensiones) sin comprometer rendimiento a lo largo del pipeline del trabajo.
El modelo se utiliza para los embeddings de imágenes, y su tokenizer se utiliza más adelante para las búsquedas mediante la codificación de texto, característica esencial para buscar similitud entre imágenes y queries.
Se aplica la normalización de los embeddings por norma L2 en el momento de su creación, para luego trabajar con métrica de coseno a lo largo del trabajo, ya que para valores normalizados su producto punto es la similitud coseno. Esta estrategia será utilizada como punto crucial para la similitud entre prompts e imágenes en la etapa de búsqueda.

Clusterización con K-Means y visualización con UMAP.

Este paso forma parte de la exploración inicial. Sus resultados se encuentran en la sección previa, pero aquí justificamos sus parámetros.
Debido a que el motivo principal de realizar esta clusterización es para visualizar luego con UMAP, elegimos una cantidad de clusters de k=100, para que se vean distinciones en el gráfico a simple vista, y que haya una diferencia para subconjuntos dentro de conceptos generales.
Se podría haber utilizado un k=20 y acercarse a que los índices sean cercanos a las 20 clases que posee el archivo Annotations, pero esto no serviría por existencia de imágenes con múltiples objetos de clases distintas. Además, tener más índices permite observar variaciones dentro de conceptos generales y permitir subconjuntos dentro, que es justamente el comportamiento que se quiere observar con esta visualización.

Crear índice con FAISS.

Una vez los embeddings fueron creados, se crea un índice sobre estos con FAISS.
Se realizó un índice IVFFLAT para primero buscar de manera aproximada por centroides y luego poder acceder a sus embeddings cercanos, para evitar una búsqueda por fuerza bruta. Para utilizar este índice, es necesario entrenarlo previamente con los embeddings obtenidos y asignar la cantidad de centroides a utilizar, que son la cantidad de áreas semánticas que se observan. La métrica utilizada es la similitud coseno, parámetro a configurar explícitamente al momento de entrenar el índice de búsqueda. Se tomó la decisión de utilizar k=400, es decir, existen 400 centroides distintos, con el objetivo de tener conceptos más aislados, permitir acercarse lo más posible a un concepto concreto con una query específica, y obtener resultados rápidos sin comprometer la exactitud.
Se probó con un k=200, pero se observó que los resultados eran de menor calidad.

Inclusión de modelo LLM

Se utilizó el modelo LLM Phi-3-mini-4k-instruct de Microsoft.
Se realizaron prompts al LLM personalizados para cada caso, ajustándolo para el método de búsqueda que se utiliza tras la traducción, creación de alternativas y detección de negativos.
En todos los usos del LLM se utilizó una temperatura de 0 para evitar que el LLM se desvíe del concepto semántico de la query original al ser demasiado creativo. Además, el parámetro "do_sample" se dejó en False para que el modelo sea completamente determinista y genere las mismas traducciones/variaciones frente a las mismas queries de entrada. Esto se hizo por repetibilidad del pipeline, y porque al utilizarlo con otros parámetros se presentaban grandes problemas en la reformulación.
Se discutirá en su apartado correspondiente las posibles causas y resultados vistos con otras variaciones.
En casos con alternativas de prompt, se tokenizan y se usa su promedio como valor a buscar mediante el índice FAISS.

Se explicará en cada caso cómo se utilizó el modelo y la estrategia de búsqueda utilizada.
Se plantearon cuatro opciones distintas:

1. **Query directo:** Sin traducción.
2. **Query traducido a inglés**: Mediante LLM, el prompt es el siguiente

```
"You are a tool. You ONLY output valid Python dictionary
strings. "
"Do not add any text, explanations, or markdown. "
"Understand the semantic meaning of the query and translate
it to                 english if it is in spanish"
"Your task is to create a search plan dictionary with one
key: "
"'translated_prompt'.\n\n"
```

3. **Query con reformulación:** Mediante LLM se solicita que se generen alternativas a la prompt introducida por el usuario, y se especifica que no la expanda de manera muy creativa (Para no perder el significado original). No se realiza tratamiento de negativos, pero se solicita que se mantenga en las alternativas de query.
   Una vez se tienen las alternativas de prompts en un diccionario, se codifican con el tokenizer del modelo CLIP, se promedian los valores de embeddings, se busca en el índice FAISS y se devuelven los scores de las diez mejores imágenes con mayor similitud coseno, junto con su nombre.
   La idea es expandir la idea original con alternativas que brinden variación semántica sin perder el significado de la query del usuario.
   La limitación de creatividad se da ya que en intentos tempranos, para una query sencilla como “person”, se obtenían resultados que agregaban contexto, como “person walking around the park”, que llevaban a un área semántica alejada del propósito original.

```
"You are a tool. You ONLY output valid Python dictionary
strings. "
"Do not add any text, explanations, or markdown. "
"Translate it to english and then create alternatives."
"Your task is to create a search plan dictionary with one
key: "
"'alternative_prompts'.\n\n"


"RULES:\n"
"1. 'alternative_prompts': List of 5 English variants of
the user query. "
 "2. Do not add extra context to the original prompt. Just
synonyms to the full query."
"3. If the query contains multiple concepts, include them
all in the reformulated query."
"4. If the query contains a negation, include those
negations in your alternative query."
```

4. **Query con reranking:** Mediante LLM se solicita que se generen alternativas a los conceptos positivos del prompt en una key de un diccionario, excluyendo los negativos. Luego, en otra key del diccionario, que se extraigan los conceptos negativos si existen, y si no, dejar vacío.
   La idea es separar los conceptos positivos de los negativos, para obtener resultados que sean lo más cercano a un concepto general sin que la negación afecte a la búsqueda, y penalizar por los conceptos negativos detectados.
   Se brindaron ejemplos de query para refinar el comportamiento esperado tras pruebas con prompts que no tenían el mismo rendimiento.

```
"You ONLY output valid Python dictionary strings. "
"Do not add any text, explanations, or markdown. "
"Understand the semantic meaning of the query and translate
it to english"
"Your task is to create a search plan dictionary with two
keys: "
"'positive_prompts' and 'negative_prompts'.\n\n"

"RULES:\n"
"0. ANALYZE THE FULL QUERY BEFORE DECIDING WHAT TO DO."
"1. 'positive_prompts': List of 5 English variants of the
query with its multiple subjects. Exclude the negated
concepts\n"
"2. 'negative_prompts': List of English translations of
explicitly negated concepts with 'no', 'sin', 'without'"
"If no explicit negations, 'negative_prompts' MUST be an
empty list [].\n\n"
"3. If the query contains multiple positive concepts,
include them all in the reformulated query."
```

```
"4. Do not add extra context to the original prompt. Just
synonyms to the full query."
"5. It is VERY important to detect the negatives correctly.
Only the explicit negations."

"EXAMPLES:\n"
"User: 'perro'\n"
"Output: {'positive_prompts': ['a photo of a dog', 'a
canine', 'a puppy', 'a dog', 'a pet dog'],
'negative_prompts': []}\n\n"

"User: 'persona jugando a la pelota con un perro'\n"
"Output: {'positive_prompts': ['a photo of a person with a
ball and a dog', 'a human playing with a soccer ball with a
canine near', 'individual with a ball and accompanied by a
puppy', 'a photo of a person playing with a dog in the
vicinity'], 'negative_prompts': []}\n\n"

"User: 'auto pero no rojo'\n"
"Output: {'positive_prompts': ['a photo of a car', 'an
automobile', 'a vehicle', 'a car', 'an image of a car'],
'negative_prompts': ['red car', 'red colored car']}\n\n"

"User: 'una persona sin un perro'\n"
"Output: {'positive_prompts': ['a photo of a person', 'a
human', 'an individual', 'a person', 'a portrait of a
person'], 'negative_prompts': ['dog', 'canine',
'puppy']}\n\n"
```

El funcionamiento para los prompts positivos es el mismo que para el caso simple de reformulación.
Para la detección de negativos se utiliza una técnica de penalización que consiste en restar al score obtenido por los conceptos que se consideran positivos, el resultado de realizar una búsqueda por los conceptos negativos multiplicado por un factor de penalización, que se ajustó empíricamente considerando los valores obtenidos y visualizados de los scores promedio.
El factor de penalización utilizado es 0,3.

```
Score final = Score positivos - (Score negativos * Factor
de penalización)
```

En los resultados se va a discutir en profundidad el impacto de este método y el valor del factor de penalización en los scores obtenidos.

Resultados

Para analizar los resultados, se utilizarán cuatro prompts específicos que engloban tres casos de uso:

1. "gato": Para verificar el funcionamiento básico de traducción de una query sencilla que forma parte de las clases de Annotations.
2. "persona trabajando en la computadora y con un gato": Para verificar el funcionamiento con una query compleja que tenga múltiples objetos.
3. "caballo blanco corriendo sin jinete": Para verificar el funcionamiento en una query que presente una negación.
4. "mujer con sombrero pero sin lentes": Otro ejemplo con negación para profundizar en funcionamiento con reranking.

Además de resultados cualitativos mediante la observación de imágenes y cómo mejora de un modelo a otro, se visualizará el funcionamiento del LLM, se calcularán métricas de precisión@10 utilizando las annotations y se calculará el promedio de score obtenido por modelo.

Para todos estos prompts se realizó análisis y comparación con dos formas de usar LLM pero los mismos prompts:

- Temperatura 0,3 y do_sample True (Modelo 0.3)
- Temperatura 0 y do_sample False (Modelo 0)

Las visualizaciones de imágenes se realizarán solamente con modelo 0,3 para facilidad de lectura.

Nota: En caso de querer visualizar todas las imágenes encontradas con el método de reranking para las 40 queries de submission, las mismas se encuentran en el notebook.

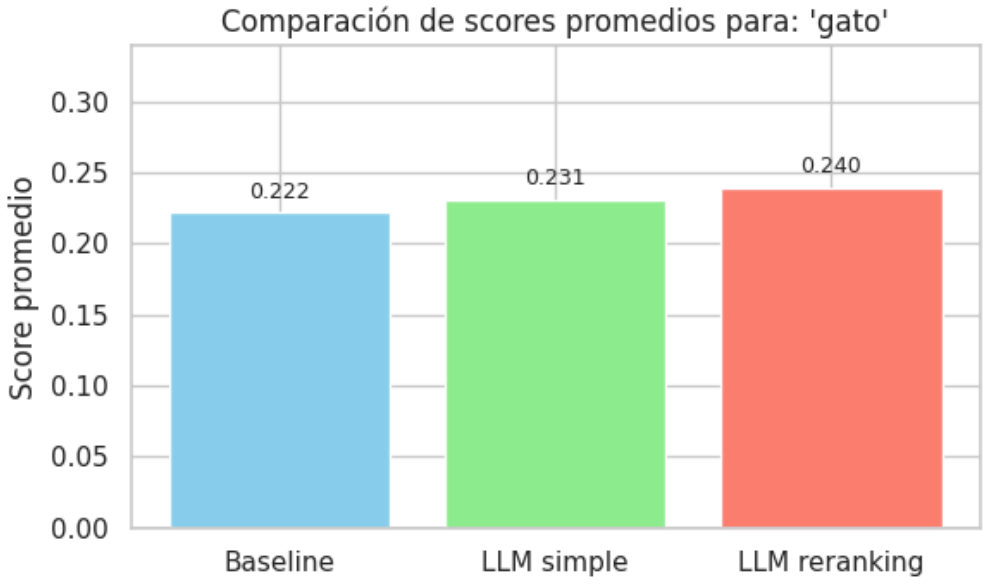
Query “gato”

Modelo 0.3

```
--------------------Búsqueda con prompt: gato--------------------
---Búsqueda de prompt traducido---
La traducción obtenida fue:  {'translated_prompt': 'cat'}
{'translated_prompt': 'cat'}
---Búsqueda de prompt reformulado---
El plan obtenido de reformulación es:  {'alternative_prompts': ['cat', 'feline', 'domestic
cat', 'house cat', 'pet cat']}
---Búsqueda de prompt con reranking---
El plan obtenido para reranking con negación es:  {'positive_prompts': ['a photo of a ca
t', 'a feline', 'a kitten', 'a cat', 'a pet cat'], 'negative_prompts': []}
```




```
---------------Scores promedios---------------
El promedio de scores para el uso baseline es:  0.22229633
El promedio de scores para el uso de LLM simple con reformulación es:  0.23110807
El promedio de scores para el uso de LLM con reranking y detección de negaciones es:  0.23
98591
---------------Precisión@10---------------
La precisión@10 para el uso baseline es:  1.0
La precisión@10 para el uso de LLM simple con reformulación es:  1.0
La precisión@10 para el uso de LLM con reranking y detección de negaciones es:  1.0
```



Modelo 0

```
La traducción obtenida fue:  {'translated_prompt': 'cat'}
{'translated_prompt': 'cat'}
---Búsqueda de prompt reformulado---
El plan obtenido de reformulación es:  {'alternative_prompts': ['cat', 'feline', 'house cat',
'domestic cat', 'pet cat']}
---Búsqueda de prompt con reranking---
El plan obtenido para reranking con negación es:  {'positive_prompts': ['a photo of a cat', 'a
feline', 'a kitten', 'a cat', 'a pet cat'], 'negative_prompts': []}

---------------Scores promedios---------------
El promedio de scores para el uso baseline es:  0.22229633
El promedio de scores para el uso de LLM simple con reformulación es:  0.23110807
El promedio de scores para el uso de LLM con reranking y detección de negaciones es:  0.23
98591
---------------Precisión@10---------------
La precisión@10 para el uso baseline es:  1.0
La precisión@10 para el uso de LLM simple con reformulación es:  1.0
La precisión@10 para el uso de LLM con reranking y detección de negaciones es:  1.0
```

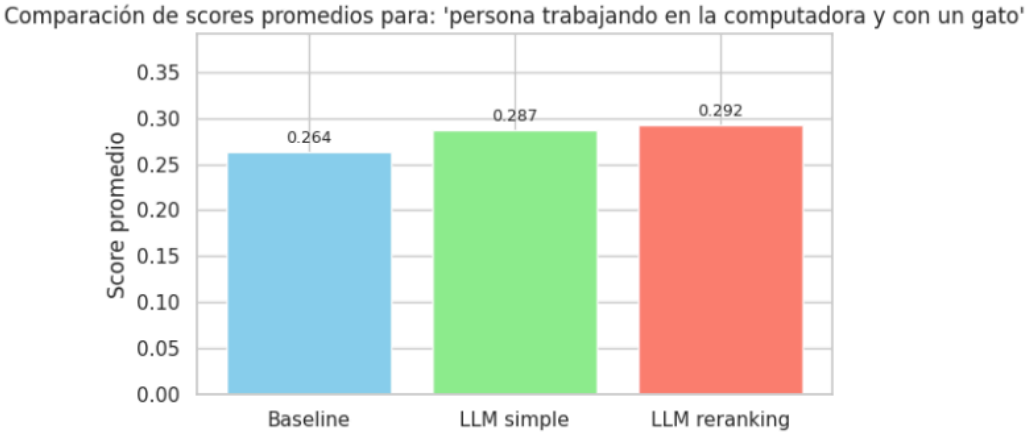
Query “persona trabajando en la computadora y con un gato”

Modelo 0.3

```
-------------------Búsqueda con prompt: persona trabajando en la computadora y con un gato
-------------------
---Búsqueda de prompt traducido---
La traducción obtenida fue:  {'translated_prompt': 'person working on the computer and wit
h a cat'}
{'translated_prompt': 'person working on the computer and with a cat'}
---Búsqueda de prompt reformulado---
El plan obtenido de reformulación es:  {'alternative_prompts': ['person working on a compu
ter with a cat', 'individual using a computer with a feline companion', 'person operating
a computer with a cat nearby', 'employee at a computer with a cat in the vicinity', 'perso
n engaged with a computer while a cat is present']}
---Búsqueda de prompt con reranking---
El plan obtenido para reranking con negación es:  {'positive_prompts': ['a photo of a pers
on working on a computer with a cat', 'an individual using a computer with a feline compan
ion', 'a person at a computer with a cat nearby', 'a picture of a person working on a comp
uter with a cat', 'a scene of a person working on a computer with a cat present'], 'negati
ve_prompts': []}
```



```
---------------Scores promedios---------------
El promedio de scores para el uso baseline es:  0.26372373
El promedio de scores para el uso de LLM simple con reformulación es:  0.2871253
El promedio de scores para el uso de LLM con reranking y detección de negaciones es:  0.29
206043
---------------Precisión@10---------------
La precisión@10 para el uso baseline es:  1.0
La precisión@10 para el uso de LLM simple con reformulación es:  1.0
La precisión@10 para el uso de LLM con reranking y detección de negaciones es:  1.0
```



Modelo 0

```
------------------Búsqueda con prompt: persona trabajando en la computadora y con un gato
------------------
---Búsqueda de prompt traducido---
La traducción obtenida fue:  {'translated_prompt': 'person working on the computer and wit
h a cat'}
{'translated_prompt': 'person working on the computer and with a cat'}
---Búsqueda de prompt reformulado---
El plan obtenido de reformulación es:  {'alternative_prompts': ['person working on the com
puter with a cat', 'individual using a computer and a cat', 'person at a computer with a f
eline companion', 'someone working on a computer with a cat nearby', 'person operating a c
omputer while a cat is present']}
---Búsqueda de prompt con reranking---
El plan obtenido para reranking con negación es:  {'positive_prompts': ['a photo of a pers
on working on a computer with a cat', 'an individual using a computer with a feline compan
ion', 'a person at a computer desk with a cat nearby', 'a person working on a computer wit
h a cat', 'a person with a cat and a computer'], 'negative_prompts': []}


---------------Scores promedios---------------
El promedio de scores para el uso baseline es:  0.26372373
El promedio de scores para el uso de LLM simple con reformulación es:  0.28537992
El promedio de scores para el uso de LLM con reranking y detección de negaciones es:  0.29
534435
---------------Precisión@10---------------
La precisión@10 para el uso baseline es:  1.0
La precisión@10 para el uso de LLM simple con reformulación es:  1.0
La precisión@10 para el uso de LLM con reranking y detección de negaciones es:  1.0
```

Query “caballo blanco corriendo sin jinete”

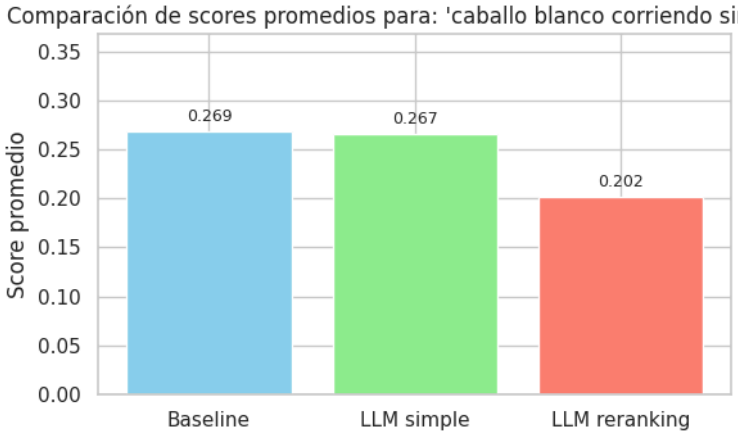
Modelo 0.3

```
------------------Búsqueda con prompt: caballo blanco corriendo sin jinete--------------
----
---Búsqueda de prompt traducido---
La traducción obtenida fue:  {'translated_prompt': 'white horse running without a rider'}
{'translated_prompt': 'white horse running without a rider'}
---Búsqueda de prompt reformulado---
El plan obtenido de reformulación es:  {'alternative_prompts': ['white horse running witho
ut a rider', 'unbridled white horse in motion', 'white horse galloping solo', 'white horse
sprinting without a reins', 'white horse running free']}
---Búsqueda de prompt con reranking---
El plan obtenido para reranking con negación es:  {'positive_prompts': ['a photo of a whit
e horse running', 'a white horse in motion', 'a galloping white horse', 'a white horse wit
hout a rider', 'a horse galloping freely'], 'negative_prompts': ['horse with a rider', 'ho
rse with a jockey', 'horse with a saddle', 'horse with a bridle', 'horse with a reins']}
Detectada negación. Penalizando por: ['horse with a rider', 'horse with a jockey', 'horse
with a saddle', 'horse with a bridle', 'horse with a reins']


/tmp/ipykernel_19/1675431762.py:32: DeprecationWarning: Conversion of an array with ndim >
0 to a scalar is deprecated, and will error in future. Ensure you extract a single element
from your array before performing this operation. (Deprecated NumPy 1.25.)
  score_negativo = float(score_negativo_array) # Convierte array([[0.25]]) a 0.25
```



```
---------------Scores promedios---------------
El promedio de scores para el uso baseline es:  0.2686817
El promedio de scores para el uso de LLM simple con reformulación es:  0.266543
El promedio de scores para el uso de LLM con reranking y detección de negaciones es:  0.20
241825699806215
---------------Precisión@10---------------
La precisión@10 para el uso baseline es:  0.4
La precisión@10 para el uso de LLM simple con reformulación es:  0.3
La precisión@10 para el uso de LLM con reranking y detección de negaciones es:  0.3
```



Modelo 0

```
--------------------Búsqueda con prompt: caballo blanco corriendo sin jinete---------------
----
---Búsqueda de prompt traducido---
La traducción obtenida fue:  {'translated_prompt': 'white horse running without a rider'}
{'translated_prompt': 'white horse running without a rider'}
---Búsqueda de prompt reformulado---
El plan obtenido de reformulación es:  {'alternative_prompts': ['white horse running witho
ut a rider', 'unridden white horse in motion', 'horse without rider, white color', 'white
horse galloping solo', 'white horse running free']}
---Búsqueda de prompt con reranking---
El plan obtenido para reranking con negación es:  {'positive_prompts': ['a photo of a whit
e horse running', 'a white horse in motion', 'a galloping white horse', 'a white horse wit
hout a rider', 'a white horse running freely'], 'negative_prompts': ['horse with a rider',
'horse with a jockey', 'horse with a saddle', 'horse with a bridle', 'horse with a rein
s']}
Detectada negación. Penalizando por: ['horse with a rider', 'horse with a jockey', 'horse
with a saddle', 'horse with a bridle', 'horse with a reins']


---------------Scores promedios---------------
El promedio de scores para el uso baseline es:  0.2686817
El promedio de scores para el uso de LLM simple con reformulación es:  0.26765293
El promedio de scores para el uso de LLM con reranking y detección de negaciones es:  0.20
09601978957653
---------------Precisión@10---------------
La precisión@10 para el uso baseline es:  0.4
La precisión@10 para el uso de LLM simple con reformulación es:  0.3
La precisión@10 para el uso de LLM con reranking y detección de negaciones es:  0.3
```

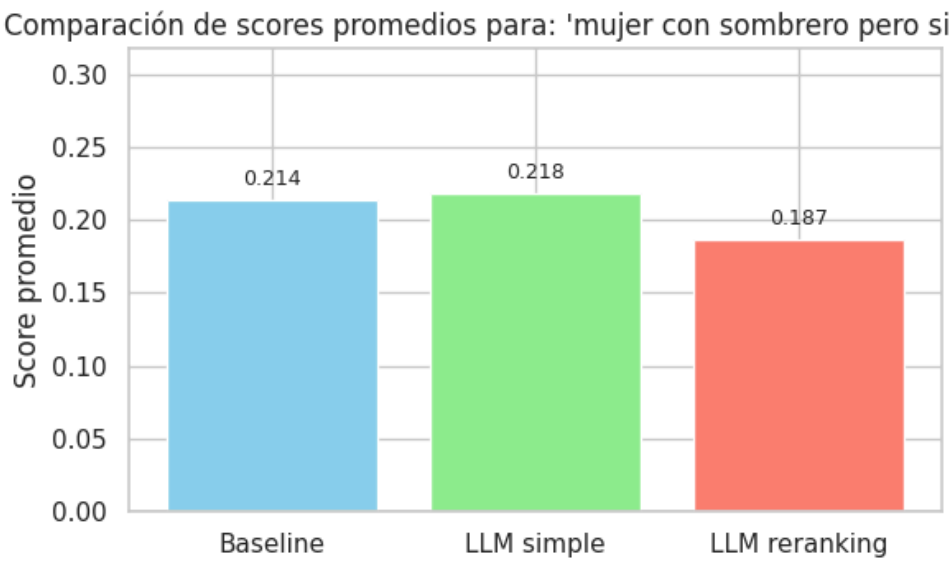
Query “mujer con sombrero pero sin lentes”

Modelo 0.3

```
------------------Búsqueda con prompt: mujer con sombrero pero sin lentes----------------
---
---Búsqueda de prompt traducido---
La traducción obtenida fue:  {'translated_prompt': 'woman with a hat but without glasses'}
{'translated_prompt': 'woman with a hat but without glasses'}
---Búsqueda de prompt reformulado---
El plan obtenido de reformulación es:  {'alternative_prompts': ['woman wearing a hat but n
ot glasses', 'female with a hat but no spectacles', 'girl with a headpiece but without eye
wear', 'woman with a hat but without glasses', 'female with a hat but no prescription glas
ses']}
---Búsqueda de prompt con reranking---
El plan obtenido para reranking con negación es:  {'positive_prompts': ['a photo of a woma
n with a hat', 'a female wearing a hat', 'a lady with a headpiece', 'a woman with a hat',
'an image of a woman with a hat'], 'negative_prompts': ['glasses', 'eyeglasses', 'spectacl
es', 'eyewear']}
Detectada negación. Penalizando por: ['glasses', 'eyeglasses', 'spectacles', 'eyewear']
```




```
---------------Scores promedios---------------
El promedio de scores para el uso baseline es:  0.21386342
El promedio de scores para el uso de LLM simple con reformulación es:  0.21830359
El promedio de scores para el uso de LLM con reranking y detección de negaciones es:  0.18
660719037055967
---------------Precisión@10---------------
La precisión@10 para el uso baseline es:  1.0
La precisión@10 para el uso de LLM simple con reformulación es:  1.0
La precisión@10 para el uso de LLM con reranking y detección de negaciones es:  1.0
```



Modelo 0

```
--------------------Búsqueda con prompt: mujer con sombrero pero sin lentes--------------------
---Búsqueda de prompt traducido---
La traducción obtenida fue:  {'translated_prompt': 'woman with a hat but without glasses'}
{'translated_prompt': 'woman with a hat but without glasses'}
---Búsqueda de prompt reformulado---
El plan obtenido de reformulación es:  {'alternative_prompts': ['woman wearing a hat but not g
lasses', 'female individual with a hat but lacking spectacles', 'a lady with a headpiece but n
o eyewear', 'a woman with a hat but no prescription glasses', 'a female person with a hat and
no glasses']}
---Búsqueda de prompt con reranking---
El plan obtenido para reranking con negación es:  {'positive_prompts': ['a photo of a woman wi
th a hat', 'a female wearing a hat', 'a lady with a head covering', 'a woman with a hat', 'an
image of a woman with a hat'], 'negative_prompts': ['with glasses', 'with spectacles', 'with e
yeglasses']}
Detectada negación. Penalizando por: ['with glasses', 'with spectacles', 'with eyeglasses']


---------------Scores promedios---------------
El promedio de scores para el uso baseline es:  0.21386342
El promedio de scores para el uso de LLM simple con reformulación es:  0.22353801
El promedio de scores para el uso de LLM con reranking y detección de negaciones es:  0.185833
401158452
---------------Precisión@10---------------
La precisión@10 para el uso baseline es:  1.0
La precisión@10 para el uso de LLM simple con reformulación es:  1.0
La precisión@10 para el uso de LLM con reranking y detección de negaciones es:  1.0
```

Conclusiones de resultados

En las dos primeras queries evaluadas, se puede visualizar que el modelo con reranking obtiene mayor valor de puntuación, seguido por el modelo de reformulación y luego la traducción del query original. Esto es esperable ya que es el orden de modelos más robustos a menos.
Sin embargo, en las negaciones se pueden visualizar diferencias sustanciales.
El score promedio disminuye en gran medida, pero se puede observar cómo las imágenes encontradas se acercan más a la query solicitada. Esta disminución del score se debe a la técnica de penalización utilizada, que siempre termina penalizando a los prompts positivos aunque no presenten de manera explícita el concepto negativo. Por el funcionamiento de CLIP, hay múltiples dimensiones semánticas que se contemplan y que terminan afectando a la similitud de las imágenes con sus textos.
Sin embargo, analizando las imágenes obtenidas, se ve cómo los topk mejoran y se penalizan a los conceptos que se toman como negativos, dejando imágenes que cumplen con el criterio de la query original o tienen un score relativo mejor a las que contienen conceptos negados.
Los scores a fin de cuenta son un valor de comparación relativo, ya que es casi imposible que se obtenga un valor de 1 en los mismos.

Métrica de evaluación mediante descomposición y unión de conjuntos

Se plantea un esquema de evaluación de un ground truth aproximado para consultas complejas con múltiples componentes obteniendo resultados parciales de cada uno, y realizando intersecciones entre dichos conjuntos.
Finalmente, se realiza una búsqueda del prompt complejo y se observa cuántas imágenes son comunes al conjunto del prompt complejo y al conjunto de la intersección de componentes.
Los prompts utilizados son los siguientes:

```
prompt_compuesto = ["auto con cielo nublado",
                    "perro con una pelota en el agua",
                    "persona leyendo un libro en un interior"]
prompt_descompuesto = [["auto", "cielo", "nubes"],
                       ["perro", "agua", "pelota"],
                       ["persona", "leer", "libro", "interior"]]
```

Como los conceptos descompuestos pueden ser muy amplios y no tener en un principio relación con otros, utilizamos una búsqueda de 4000 candidatos para quedarse con los 2000 mejores de cada conjunto individual.
A estos, les realizamos una intersección con los conjuntos de conceptos descompuestos y obtenemos la cantidad de imágenes que cumplen el rol de ground truth aproximado.
Realizamos dos búsquedas, cambiando los parámetros de la búsqueda del conjunto compuesto para tener una idea general de las imágenes que cumplen con las prompts creadas.

top_k = 10 k_candidates = 1000

```
Descomposición para  auto con cielo nublado
Imágenes en el resultado compuesto: 10
Imágenes en el ground truth aproximado: 28
Intersección: 2
Unión: 36
IoU (intersección sobre unión) ≈ 0.056

Descomposición para  perro con una pelota en el agua
Imágenes en el resultado compuesto: 10
Imágenes en el ground truth aproximado: 79
Intersección: 0
Unión: 89
IoU (intersección sobre unión) ≈ 0.000

Descomposición para  persona leyendo un libro en un interior
Imágenes en el resultado compuesto: 10
Imágenes en el ground truth aproximado: 40
Intersección: 1
Unión: 49
IoU (intersección sobre unión) ≈ 0.020
```

top_k = 1000 k_candidates = 2000 comp

```
Descomposición para  auto con cielo nublado
Imágenes en el resultado compuesto: 1000
Imágenes en el ground truth aproximado: 28
Intersección: 27
Unión: 1001
IoU (intersección sobre unión) ≈ 0.027

Descomposición para  perro con una pelota en el agua
Imágenes en el resultado compuesto: 1000
Imágenes en el ground truth aproximado: 79
Intersección: 32
Unión: 1047
IoU (intersección sobre unión) ≈ 0.031

Descomposición para  persona leyendo un libro en un interior
Imágenes en el resultado compuesto: 1000
Imágenes en el ground truth aproximado: 82
Intersección: 69
Unión: 1013
IoU (intersección sobre unión) ≈ 0.068
```

El valor IoU no tiene mucho valor por sí mismo ya que pueden haber múltiples imágenes que queden por fuera. Lo que realmente vale es ver la intersección entre el conjunto compuesto y el conjunto de descomposiciones.
Además, dependiendo de la cantidad de top_k que se utilicen varía. Sin embargo, tomaremos el top_k = 10, como usamos a lo largo del desarrollo del trabajo.

Discusión y análisis crítico

¿Qué funcionó bien?:

- Utilización de temperatura 0 y do_sample = False en LLM: Esta decisión se tomó debido a que con temperatura 0,3 y do_sample = True, a veces el LLM de reformulación confundía la orden (El prompt) por la query a buscar.
- Sin embargo, esta creatividad extra que se le permite al LLM permite una variación semántica mayor, por lo que se incluyeron resultados con su funcionamiento. Esto también lleva a variaciones sutiles en cada ejecución de búsquedas, incluso para las mismas queries.
- Incluir ejemplos esperados de comportamiento en el prompt de reranking del LLM mejoró mucho la estabilidad del mismo, lo que permitió tener un manejo de negaciones aceptable.

¿Qué intentos no funcionaron y por qué?:

- No todas las imágenes están correctamente etiquetadas en Annotations, por lo que las métricas de precisión no son del todo aplicables. Por ejemplo, en el análisis para “persona trabajando en la computadora y con un gato”, múltiples imágenes tenían solamente la etiqueta de “cat” sin contar con la de “person”, por lo que se modificó la estrategía para encontrar ALGUNA de las etiquetas esperadas, en vez de todas.
- Se barajó la posibilidad de utilizar otros LLM como TinyLlama, pero no se pudo integrar en el entorno de Kaggle, por lo que se optó por phi3mini.
- El prompt realizado a los LLM fue una de las grandes fuentes de problemas del trabajo. Hasta encontrar un prompt lo suficientemente robusto y flexible que permitiera tener resultados aceptables, el mismo pasó por múltiples iteraciones.
- Se realizó PCA en embeddings y en uso de índices con el propósito de reducir ruido, pero a la hora de realizar las búsquedas los resultados no tenían coherencia con el query planteado, por lo que se descartó completamente del trabajo. Posiblemente se deba a que se perdían más detalles de lo esperado. Se probó reducir a 50 dimensiones y a 256, pero en ambos casos los resultados no tenían sentido.

Limitaciones del enfoque:

- Como se mencionó previamente, la principal limitación fue el LLM. El realizar un prompt que contemple todo lo necesario y que involucre el análisis semántico deseado, escapa de las capacidades de un modelo liviano.
  Se busca un balance entre que el prompt dé resultados sin que el mismo sea de gran longitud, ya que el modelo no lo soporta.

Trabajo futuro

Algunas posibles mejoras que nos parece interesante realizar son:

- Utilizar un modelo de lenguaje más avanzado, que tenga mayores capacidades de comprensión semántica. Sería interesante ver hasta qué punto se podría mejorar la similitud y qué tan preciso se puede hacer una query.
- Realizar un prompt robusto que ayude a tener un análisis semántico mucho mayor de las frases, y que pueda detectar negativos de manera confiable.
- Con más tiempo nos habría gustado realizar más métricas que no involucren las annotations, ver hasta qué punto se puede llegar a generar métricas cuantitativas que no requieran de comparar visualmente las imágenes.
- Realizar pruebas con otros LLM que estén más especializados.
- Realizar pruebas con modelos de CLIP que tengan más dimensionalidad, para analizar, como en el primer punto, hasta qué punto se puede tener un embedding y una query más compleja que represente conceptos semánticos específicos.

Conclusión

En este trabajo práctico de la materia de inteligencia artificial, se realizó una pipeline completo para un sistema de búsqueda multimodal de imágenes utilizando las tecnologías CLIP para la conversión de imágenes y texto a embeddings que contienen el significado semántico de los mismos, FAISS para la creación de índices y un LLM para la traducción, reformulación y detección de negativos en una serie de queries planteadas en el dataset Pascal 2012 VOC y otras planteadas por la cátedra.
El trabajo incluyó la creación de métricas propias para la similitud entre imágenes y prompts complejas, y es un trabajo integral que nos permitió ver en profundidad el funcionamiento y la utilidad del uso de modelos de lenguaje y redes neuronales.